



Analysis of a sleep-dependent neuronal feedback loop

HW o2

Alireza Shirzad_Alireza Kazemi_Mahdi Sedighi|Student ID : 9510184 _9510503 _ 5101893

Computational Neuroscince| April 2018

Part 1

QUESTION 1 :

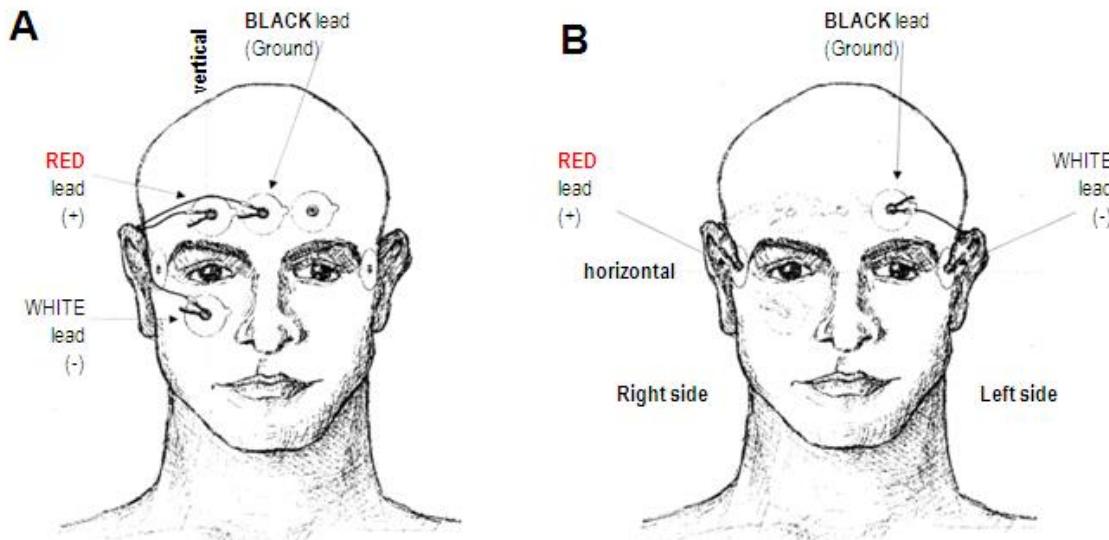
هدف کلی این مقاله ارائه‌ی طرحی سیستمی برای مدل سازی مغز در زمان خواب، بر اساس عمق خواب است. خواب هر انسان از دو بخش REM و NREM تشکیل شده که بحث عمق خواب در حالت NREM مطرح می‌شود. عمق خواب NREM رابطه‌ی مستقیمی با مقدار دامنه‌ی مولفه‌های فرکانس پایین مغز دارد لذا معیار ما قطعاً تابعی است از این مولفه. چون در این مقاله ما کار ما در حوزه فرکانس است، رزولوشن زمانی محدودی داریم زیرا اگر time bin‌ها را بسیار کوچک کنیم، آنالیز فرکانسی برای آن معنی ندارد. در این پژوهه time bin‌ها ۱۰ ثانیه تعریف شده‌اند.

QUESTION 2 :

این آزمایش بدین صورت انجام شد که ۲۴ نفر برای ۲ شب تحت آزمایش قرار گرفتند. عده‌ای شب اول و عده‌ای شب دوم، قرص temazepam دریافت کردند (در دیگر شب به آن‌ها اسمارتیز داده شده !!!). این افراد متشکل از زن و مرد در سنین مختلف (۱۸-۷۹) هستند. در طول مدت خواب از آن‌ها polysomnogram و hypnograms گرفته شده.

شامل EEG، یک سیگنال EOG و یک سیگنال EMG می‌باشد. Hypnogram polysomnogram های خواب و زمان ابتدای آن state می‌باشد که به طور synchronized State با هم ضبط شده‌اند.

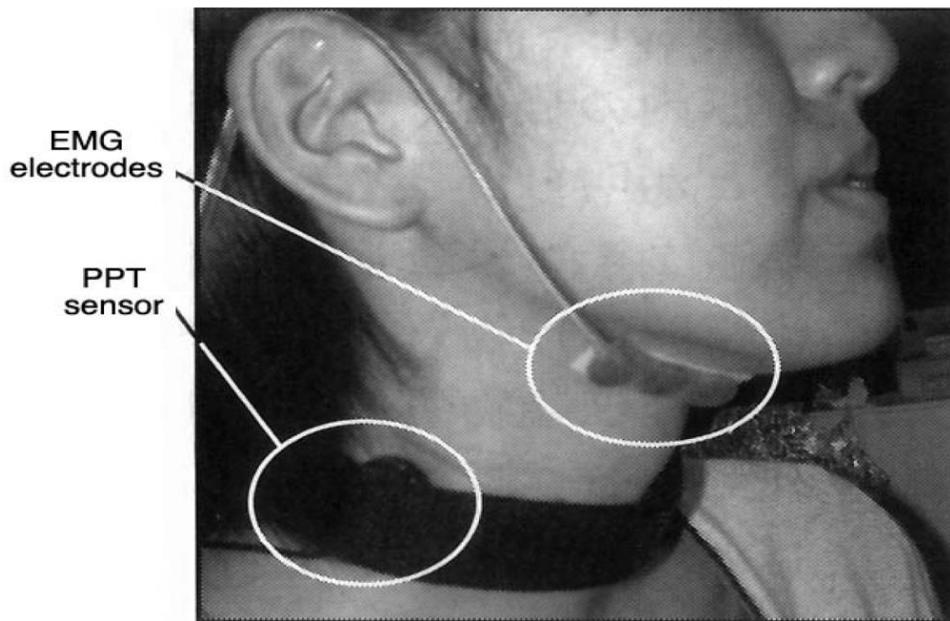
سیگنال EOG اثرات حرکت چشم را در سیگنال نشان می‌دهد. چشم انسان مانند دوقطبی‌ای است که با حرکت محل قطب هایش تغییر می‌کند. قرنیه نسبت به retina پتانسیل بیشتری دارد. EOG را میتوان به دو شکل اندازه گرفت، یکی با قرار دادن الکترود‌ها به صورت افقی و دیگری به صورت عمودی. در این آزمایش از الکترود‌های افقی به شکل زیر استفاده شده.



شکل ۱: موقعیت الکترود های EOG

شکل سمت راست به صورت افقی EOGHorizontal _ شکل سمت چپ به صورت عمودی EOGVertical

سیگنال EMG، پتانسیل حاصله از ماهیچه‌های نورون‌ها ندارد. ماهیت این سیگنال، ونتازی است که عضلات با حرکت خود ایجاد می‌کنند.



شکل 2 : موقعیت الکترود های EMGSubmental

QUESTION 3 :

در پژوهش های پیشین ، محققان تصور می کردند که عمق خواب رابطه ای مستقیم با power مولفه های short_wave دارد . این باور اشکالات مهمی دارد من جمله این که power با عوامل خارجی و آناتومیکی که ربطی به خواب ندارند تعییر می کند . به عنوان مثال (SWP) Short Wave Parametere در خواب زنان حدوداً دو برابر خواب مردان بود لذا همگان بر این باور بودند که خواب زنان عمیق تر از خواب مردان است . اما در این مقاله معیار جدیدی به نام SW% ارائه شد که درصد SW را در کل سیگنال نشان می دهد . این معیار تحت تاثیر عوامل نامرتب نیست .

QUESTION 4 :

مدلی که در این مقاله ارائه شده ، بر اساس فیدبکی است که میزان مولفه ای فرکانس پایین را در در مغز تنظیم می کند . این فیدبک ، دامنه ای این مولفه را در مقدار (t)p ضرب می کند که نمایانگر عمق خواب است . این حلقه ای فیدبک بر اساس مقدار مولفه ای فرکانس پایین زمان حال که با یک فیلتر رزونانسی از سیگنال های مغز جدا می شود و gain فیدبک که با عمق خواب مشخص می شود کامل می شود . یعنی عمق خواب در آینده ای نزدیک به میزان SWP حال مغز بستگی دارد . سپس این سیگنال تحت یک فیلتر پایین گذر قرار می گیرد و تحت عوامل خارجی که به شکل یک فاکتور ضرب کننده مدل شده اند ، به پوست سر و سپس به EEG می رسد . این نگاه کاملاً سیستمی است و در اکثر موارد انطباق کامل با مشاهدات عینی دارد .

Part 2 :

QUESTION 1 :

مطالعه کردیم .

QUESTION 2 :

در ابتدای تابع ، با دستور های AnnotExtract و edfread دو فایل hypnogram را load می کنیم . بردار state را به سادگی با تقسیم بازه های خواب به بازه های 10 ثانیه ای بدست می آوریم . هر درایه زمان آغاز بازه را نشان می دهد . سپس به اندازه طول بردار t بردار state را می سازیم که به کمک بردار های hypnogram بدست می آیند . تنها کافی است که به هر 10 ثانیه state ه خود را نسبت دهیم . برای ساختن ماتریس X با یک for به اندازه تعداد درایه های time به اندازه 1000 درایه روی 4 سیگنال پیش می رویم . در هر step میزان power های خواسته شده را با دستور bandpower بدست می آوریم . این تابع با گرفتن فرکانس sample برداری ، ابتداء و انتهای باند و سیگنال مورد نظر ، توان در آن بازه را به ما دهد .

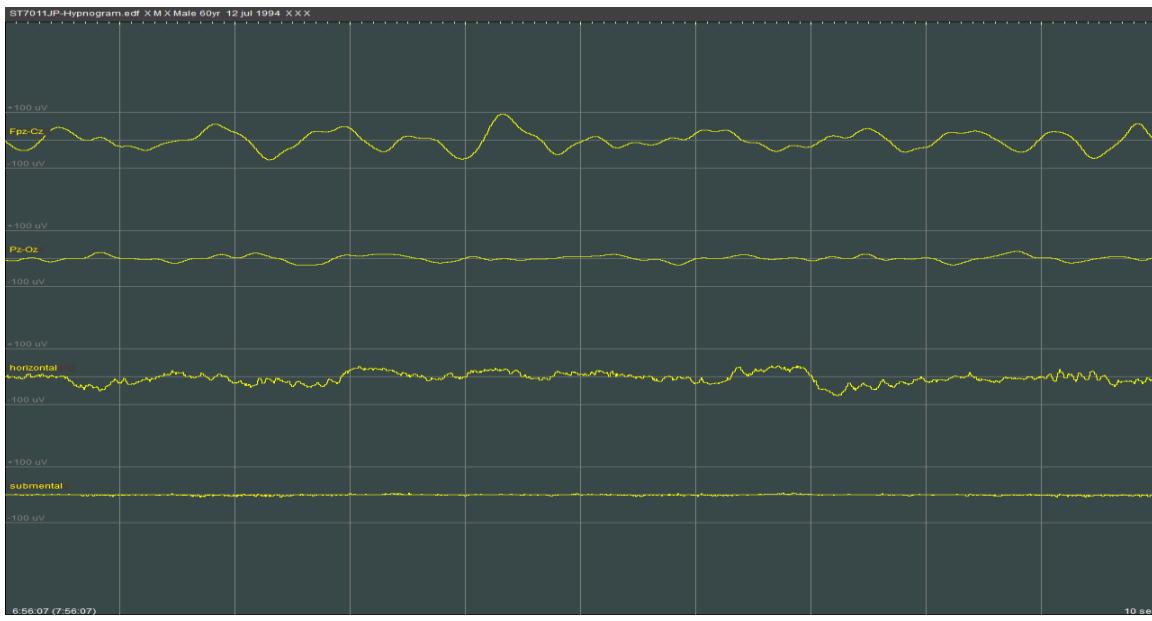
QUESTION 3 :

برای بررسی عمق خواب طبق ادعای مقاله ابتداء دو سیگنال EEG را در نرم افزار edfreader تحت یک فیلتر Bandpass ، با فرکانس ابتدای Hz 0.5 و انتهای Hz 4 و با order 10 از یک فیلتر butterworth می گذرانیم . حال برای state های مختلف سیگنال ها را بررسی می کنیم .



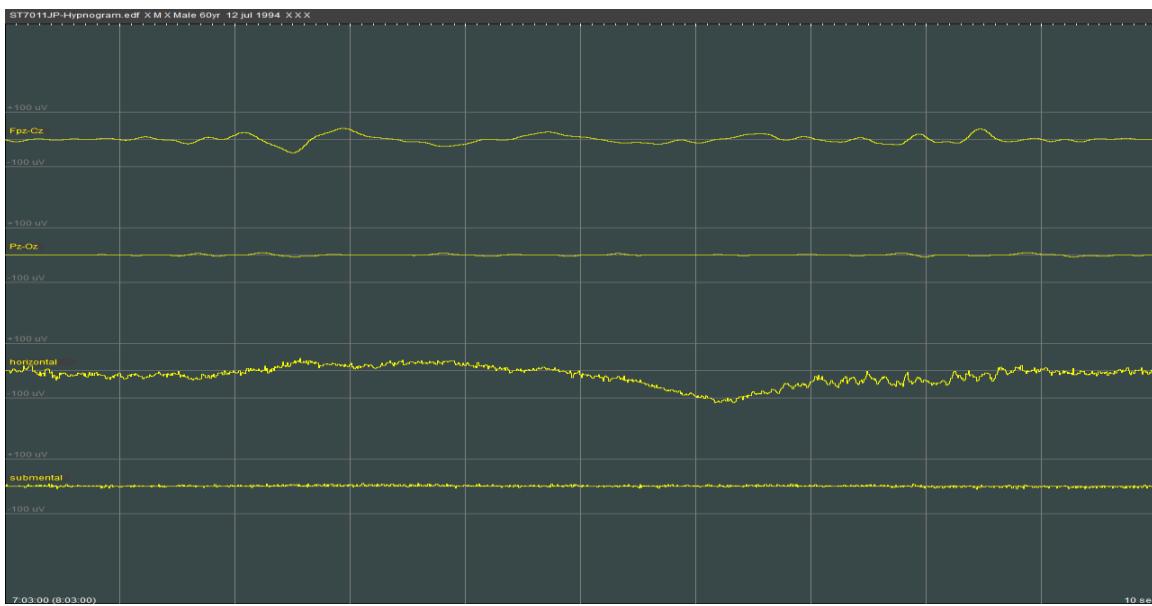
شکل 3: به ترتیب از بالا سیگنال های EEG OzCz و EEG FpzOZ و EMG Submental و EOG Horizontal فیلتر شده

برای 1 خواب state



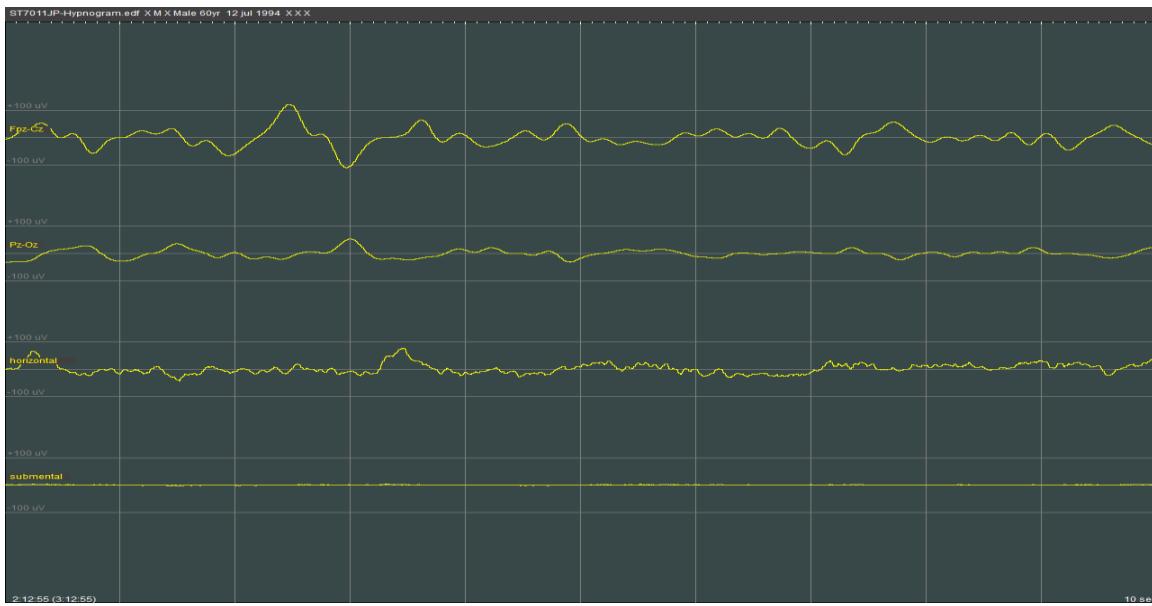
شکل ۴ : به ترتیب از بالا سیگنال های EEG OzCz و EEG FpzOZ فیلتر شده
EMG Submental و EOG Horizontal

برای state ۲ خواب



شکل ۵ : به ترتیب از بالا سیگنال های EEG OzCz و EEG FpzOZ فیلتر شده
EMG Submental و EOG Horizontal

برای state ۳ خواب

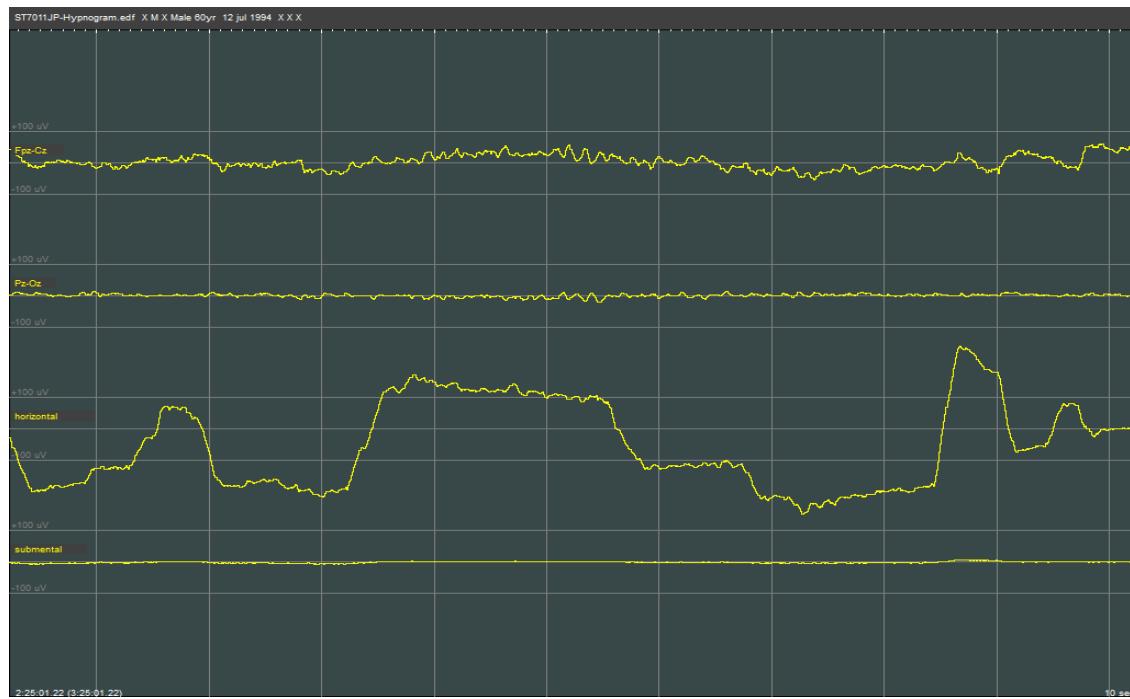


شکل 6 : به ترتیب از بالا سیگنال های EEGOzCz و EEGFpzOZ فیلتر شده
EMGSubmental و EOGHorizontal

برای خواب state 4

همانطور که مشاهده می شود دامنه ی SW با افزایش state ها افزایش می یابد . همچنین سیگنال های EOGHorizontal و EMGSubmental نقریبا ثابت و بدون نوسانات هستند .

حال نگاهی با حالت REM بیندازیم :



**شکل ۵ : به ترتیب از بالا سیگنال های EEG OzCz و EEG FpzOZ فیلتر شده
EMG Submental و EOG Horizontal**

REM State برای

همانطور که مشاهده می شود میزان نوسانات سیگنال EOG در حالت REM بسیار زیاد می شود . این اتفاق به خاطر حرکات چشم در زمان خواب REM است که در سیگنال EOG منعکس می شود .

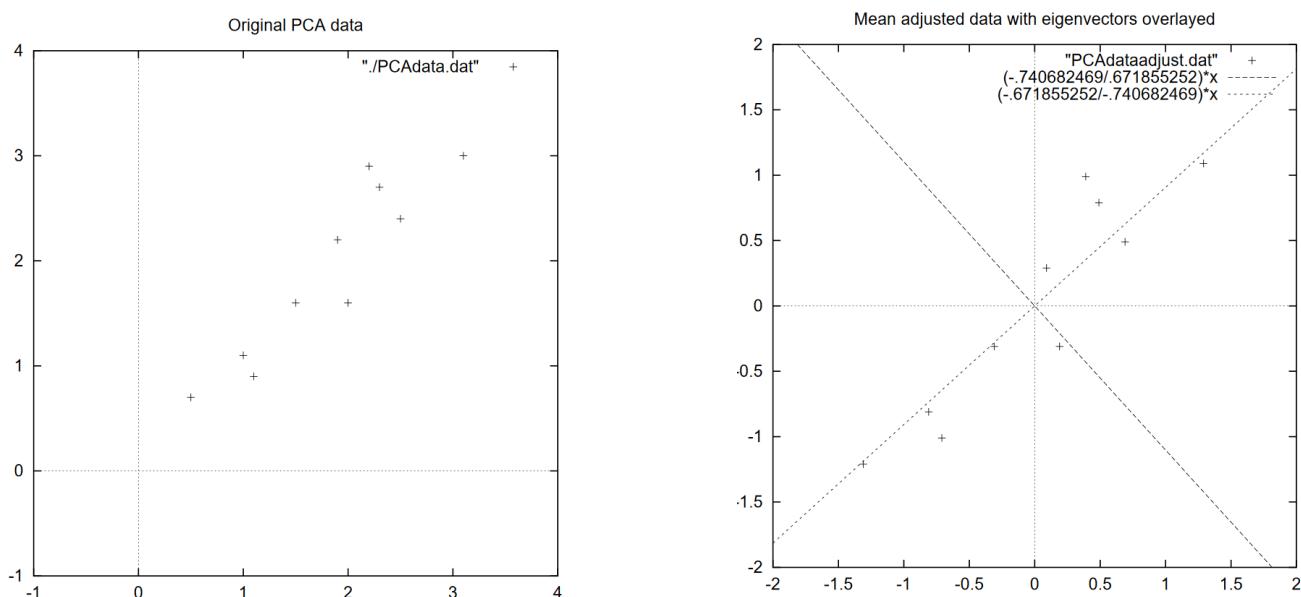
Part 3

QUESTION 1:

تابع PCA ، یک سری نقطه را در فضای آن را دریافت می کند و **basis vector** های آن فضای آن را تغییر می دهد . در واقع اگر n نقطه در فضای m بعدی به آن بدهیم ، خروجی n نقطه در فضای m بعدی دیگری است که **basis vector** ها ترکیب خطی **eigenvector** های قبلی هستند . حال این **Vector** ها همان **Covariance matrix** های ماتریس **eigenvector** داده ها هستند .

$$C = \begin{pmatrix} cov(x, x) & cov(x, y) & cov(x, z) \\ cov(y, x) & cov(y, y) & cov(y, z) \\ cov(z, x) & cov(z, y) & cov(z, z) \end{pmatrix}$$

این **eigenvalue** ها متضاد با **eigenvector** هایی هستند که واریانس داده ها در آن راستا را نشان می دهد . این **eigenvalue** ها را اگر **sort** کنیم راستاهایی را به ما می دهد که داده های ما بیشترین کشیدگی را در فضای دارند . حال می توانیم **eigenvalue** هایی با **eigenvector** هایی بسیار بزرگ را نگه داریم و بقیه را دور بریزیم و داده هایمان را تنها با آن بردار ها توصیف کنیم . بدین ترتیب ابعاد فضای ما کاهش یافته .



شکل 6

تابع **pca** سه خروجی دارد که عبارت است از :

Coeff ، **Score** ، **latent** .

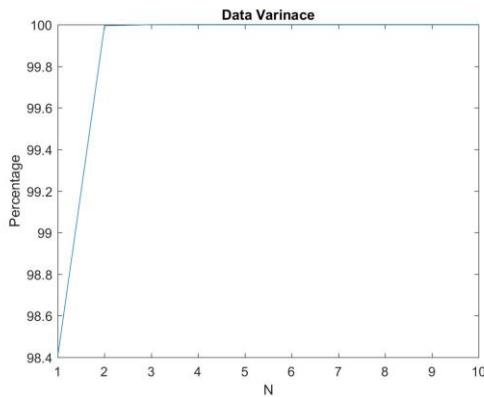
خروجی **latent** مقادیر ویژه ای ماتریس Covariance را به صورت **sort** شده می دهد .

خروجی **Coeff** بردار ویژه ای بدست آمده را بر حسب پایه های اصلی فضای به ما می دهد .

خروجی **Score** ، دیتا است را بر حسب بردار ویژه ها بیان می کند .

QUESTION 2 :

ماتریس X که دیتا ست ماست دارای 10 ستون به عنوان $feature_1$ و n ردهف که هر کدام متعلق به یک نقطه در آن فضای 10 بعدی است. روی این ماتریس PCA می‌زنیم. خروجی latent مقدار واریانس یا همان پخش شدگی داده‌ها در راستا‌های بدست آمده را نشان می‌دهد. حال مقدار واریانس پوشش داده شده توسط بردار ویژه‌ها، با m بردار ویژه‌ی اول را بر حسب m نمایش می‌دهیم.



شکل 7

همانطور که مشاهده می‌شود با گرفتن سه Eigenvector اول، تقریباً 100 درصد کشیدگی فضا پوشش داده می‌شود. لذا می‌توانیم با خیال راحت داده‌هایمان را با همین سه بردار نمایش دهیم و 7 بردار دیگر را دور بریزیم.

QUESTION 3 :

در این بخش ابتدا دادها را بر اساس `label` آن‌ها جدا می‌کنیم. بدین صورت که در بردار `state` با دستور `find`، اندیس‌های فلان `state` را خارج می‌کنیم. سپس با توجه به اندیس‌ها جمعی از خانه‌های ماتریس X (برحسب ردیف) را با یک `label` کنار می‌گذاریم. مثلاً برای 4 `state` `label`:

```
four_state_ind = find (state == 4);

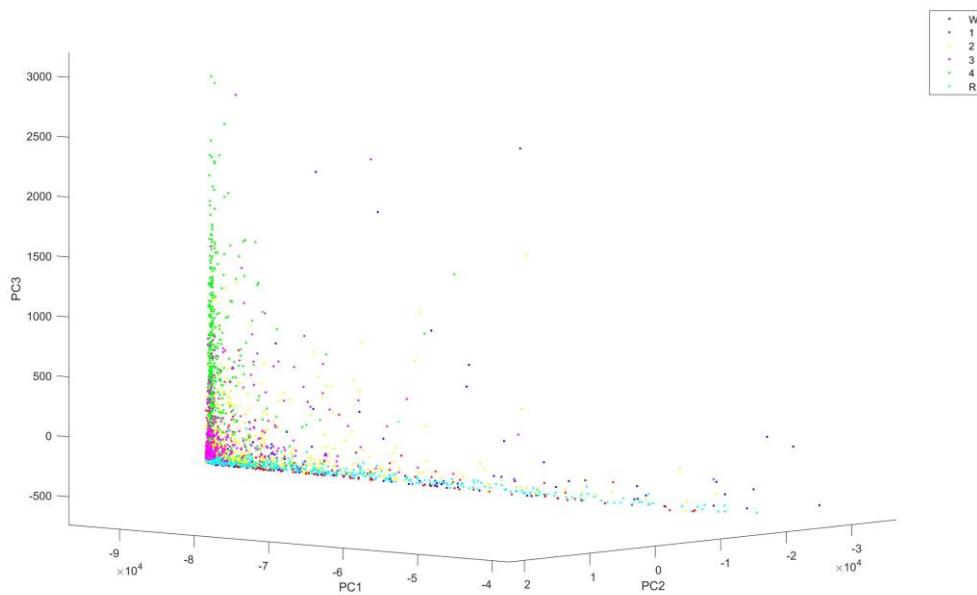
fourthState1 = X1(four_state_ind) ;

fourthState2 = X2(four_state_ind) ;

fourthState3 = X3(four_state_ind) ;
```

که X_1 و X_2 و X_3 ستون‌های اول تا سوم ماتریس `Score` می‌باشند.

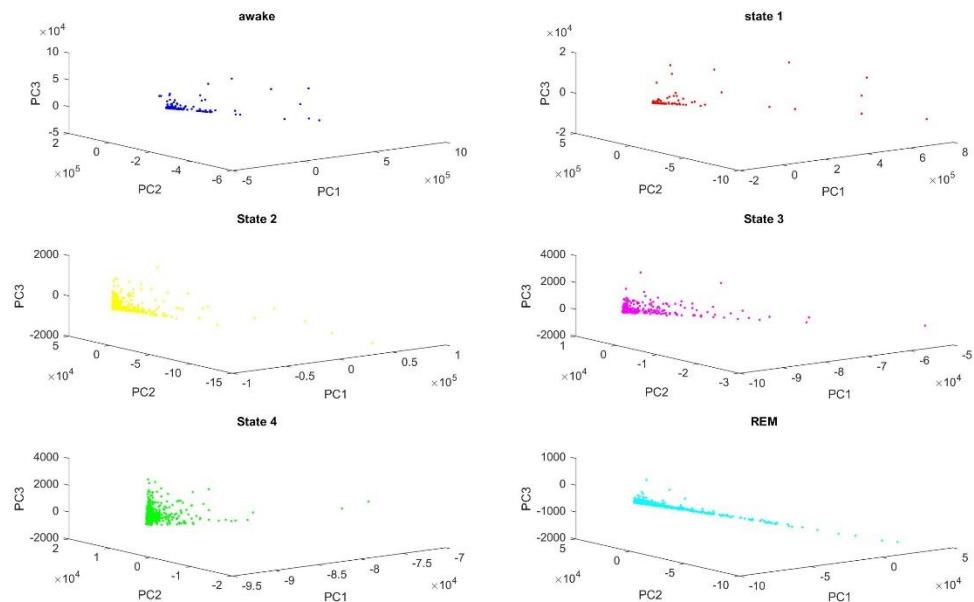
حال داده‌های مربوط به هر یک از `state`‌ها را با توجه به `label` آن‌ها که با الگوریتم بالا جدا شدند، با رنگ‌های مختلف، در فضای سه بعدی PC_1 و PC_2 و PC_3 Scatter می‌کنیم. نتیجه بدین شکل بود (با zoom).



شکل 8

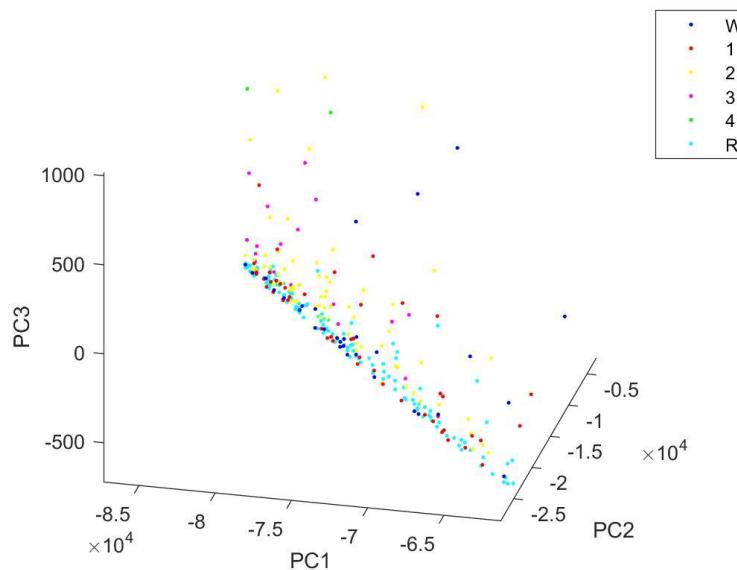
QUESTION 4 :

ابتدا شمای کلی از همه حالت های خواب به صورت جدا جدا ، در یک قاب بینیم .



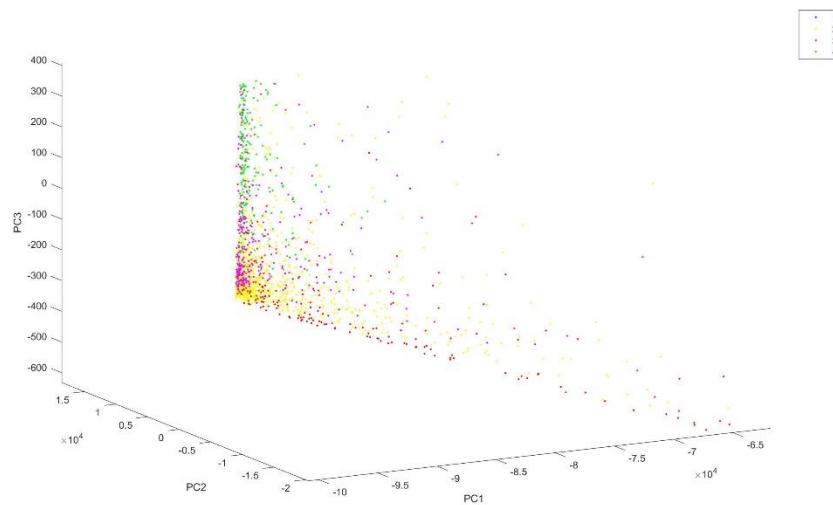
شکل 9

همانطور که می بینید در حالت بیداری ، نقاط ، پراکندگی بیشتری دارند و کمی clustering ان ها مشکل است . دلیل این مسئله این است که در حالت بیداری حرکات غیر قابل پیش‌بینی ممکن است از انسان سر بر زند لذا دیتا ها از نظم به خصوصی پیروی نمی کنند . در رابطه با نزدیکی داده ها در بخش آخر مفصل صحبت می کنیم .



شکل 10

طبق شکل بالا نقاط REM تقریبا به صورت خطی در صفحه PC_1 و PC_2 در آمده که PC_3 آن ها ثابت است . یعنی با داشتن مقدار تقریبی PC_1 یا PC_2 مولفه دیگری بدست می‌اید . همچنین با داشتن PC_3 متوجه می‌شویم که در حالت REM است .



شکل 11

مشاهده می کنیم که عمق خواب NREM با تغییر PC₃ ، بیشترین تغییر را دارد یعنی محور PC₃ می تواند معیار خوبی برای تعیین عمق خواب باشد . در سئوال بعد توضیح می دهیم که چرا این چنین است و چرا ما چنین انتظاری را نیز داشتیم .

QUESTION 4 :

برای پی بردن به ارتباط بردار های پایه ای جدید فضای 10 بعد قبلی ، به خروجی Cooeff مشاهده میکنیم . این خروجی بردار های پایه جدید را بر حسب بردار های پایه قبلی بیان می کند .

-0.0004	-0.0009	0.1119
-0.0000	-0.0000	0.0026
-0.0000	-0.0000	0.0025
-0.0000	-0.0002	0.0039
-0.0001	-0.0124	0.9936
-0.0000	-0.0000	0.0034
-0.0000	-0.0000	0.0014
-0.0000	-0.0001	0.0016
0.7126	-0.7015	-0.0087
0.7016	0.7126	0.0090

ستون اول به ما می گوید که محور PC₁ در جهت افزایش power چنل های EOGhorizontal و EMGsubmental است و در ارتباط زیادی با مولفه های دیگر ندارد .

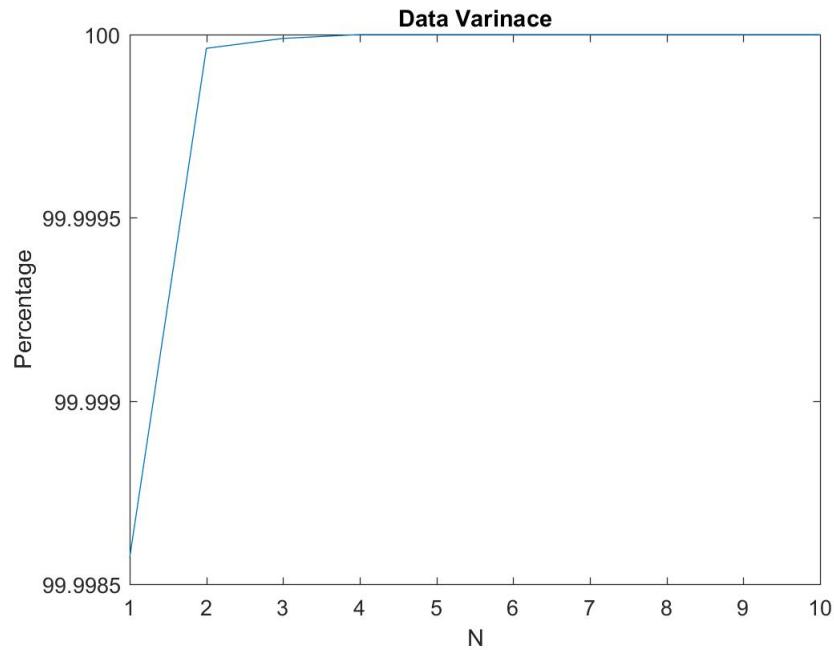
ستون دوم نیز مانند ستون اول رفتار مشابهی برای محور PC₂ نشان می دهد .

اما ستون سوم به مقدار زیادی در جهت Feature پنجم یعنی توان باند دلتای سیگنال EEGPzOz است و به مقدار کمتری به توان باند دلتای سیگنال EEGFpzCz بستگی دارد .

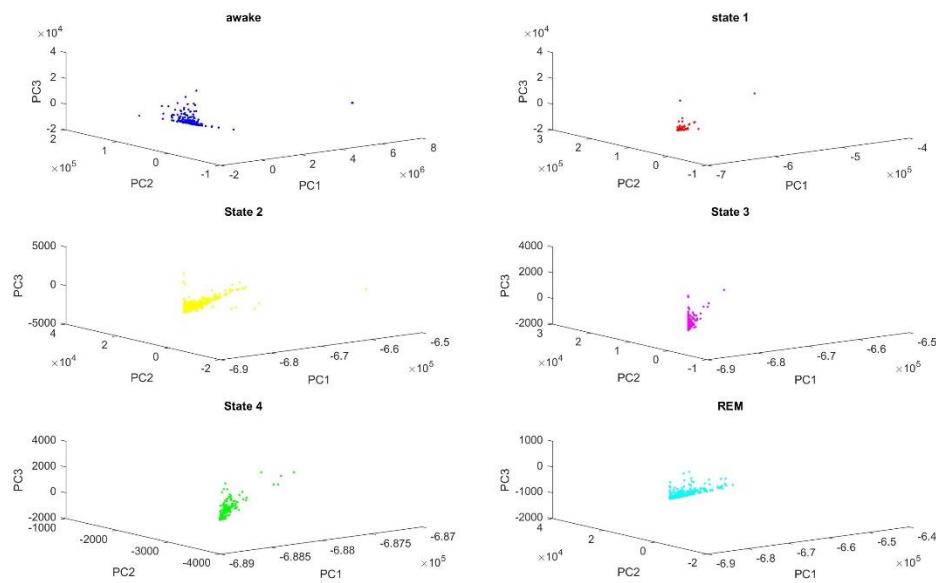
پس با نتایج بالا state خواب را عملا می توانیم با داشتن power باند دلتای سیگنال EOGhorizontal و EMGsubmental و داشتن power باند دلتای سیگنال های EEGPzOz و EEGFpzCz تخمین بزنیم . حال به تبیین ارتباط state ها با این کیت ها می پردازیم . با توجه به سئوال قبل هر چقدر مقدار مولفه ای PC₃ بیشتر باشد عمق خواب NREM بیشتر است . از طرفی می دانیم افزایش PC₃ به معنای افزایش توان باند دلتای دو کanal EEG است که این موضوع با ادعای مقاله کاملاً سازگار است . مقاله معیار عمق خواب را میزان توان باند کم فرکانس می دانست لذا این نتایج بر گفته ای مقاله صحه می گذارد . با توجه به شکل 3 در حالت REM ، مقدار PC₁ و PC₂ کمی بیشتر از حالت های دیگر است و این بدین معنی است که حالت REM دارای پاور به نسبت زیاد EOGhorizontal و EMGsubmental و پاور باند دلتای EEG نسبتا کم است . حالت REM آخرین حالت ماقبل بیداری است . در این state عملکرد مغز دقیقاً مانند زمانی است که ما بیداریم یا روی چیزی تمرکز کرده ایم . فشار خون ، ضربان قلب ، دمای بدن و دیگر علائم حیاتی نیز در این state به شدت بالا می رود . به همین خاطر است که ما در سیگنال های EOG و EMG نسبتا پاور بیشتری داریم . سیگنال EOG حرکات چشم را مانیتور می کند و همانطور که از اسم REM بر می آید ، حرکات چشم زیاد می شود لذا پاور EOG زیاد می شود . سیگنال EMG نیز حرکات Muscular را مانیتور می کند که قاعدها باید در state های awake و REM منعکس شود .

QUESTION 6 :

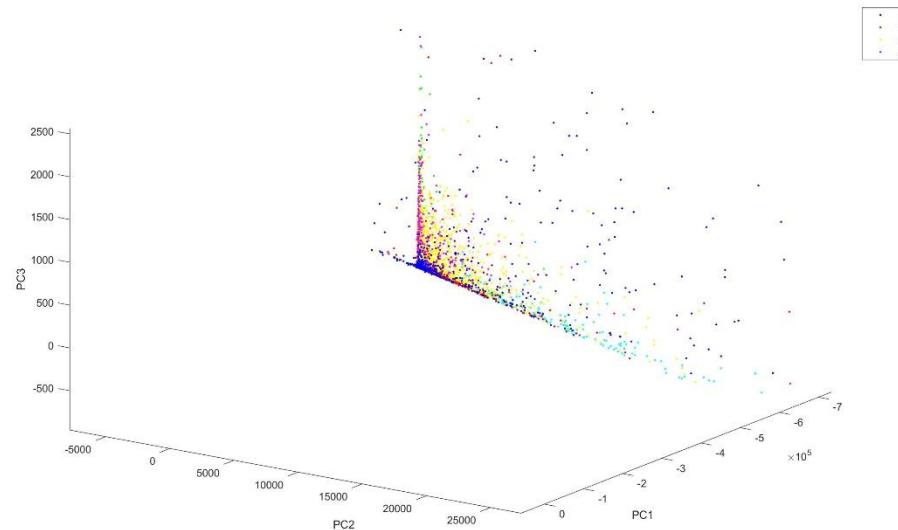
همین کار ها را برای **Subject 1 (ST7011Jo)** بدهید .
تکرار میکنیم . نتایج بدست آمده به شکل زیر می باشد .



شکل 12 : نمودار تجمعی انرژی فضای بر حسب بردار های ویژه برای **subject 1**

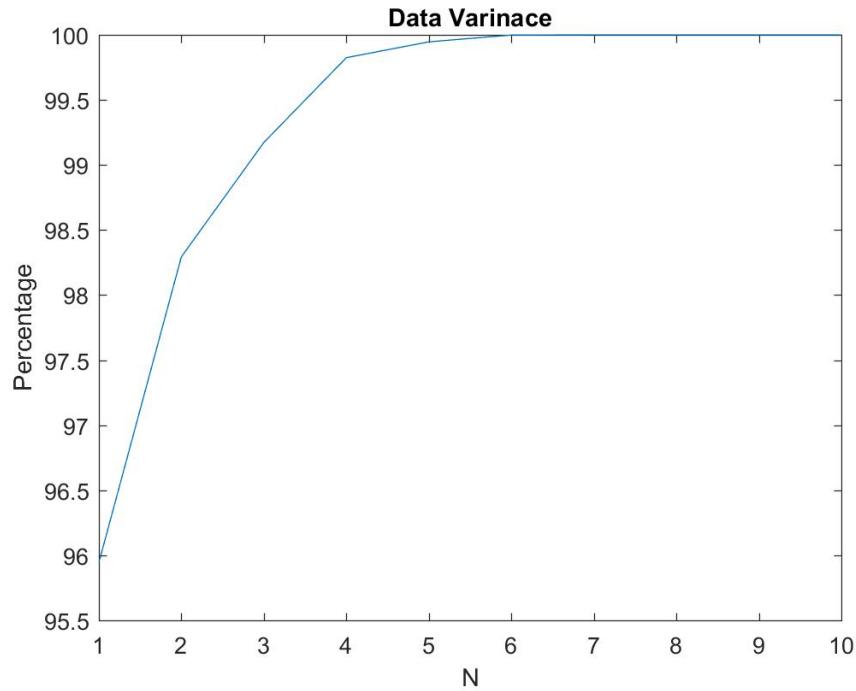


شکل 13: نقاط های مختلف خواب برای subject 1

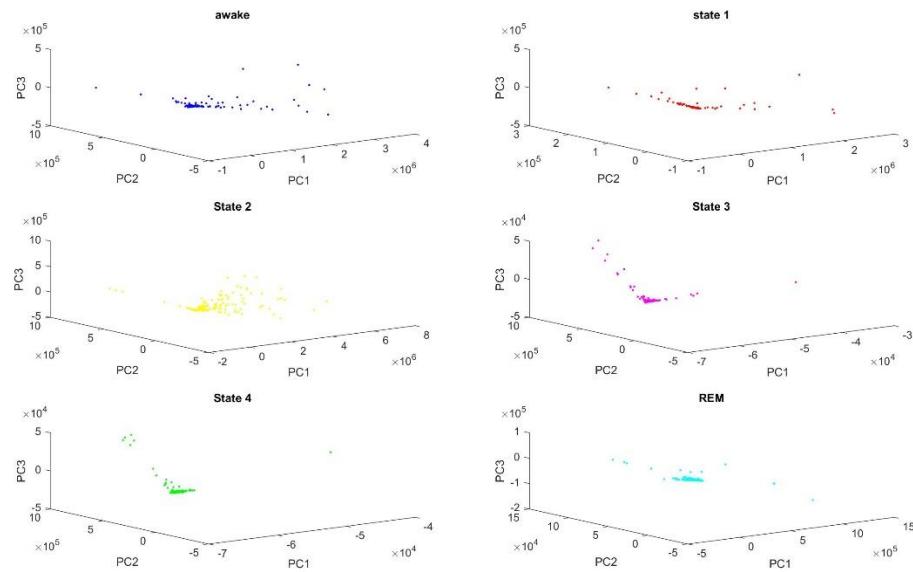


شکل 14: نقاط های مختلف خواب برای subject 1

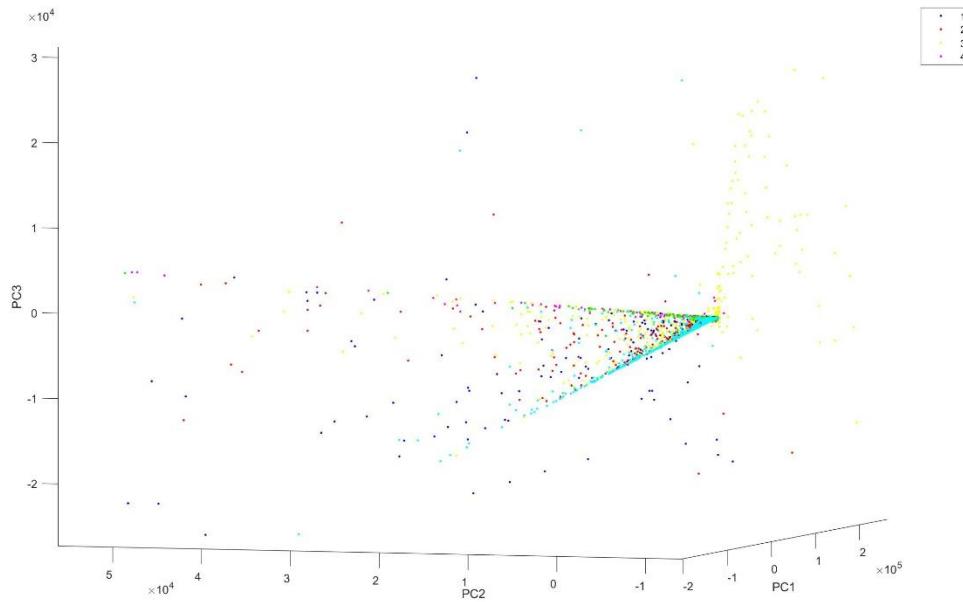
برای (ST7041Jo) subject 3 داریم :



شکل 15: نمودار تجمعی انرژی فضای بر حسب بردار های ویژه برای subject 3

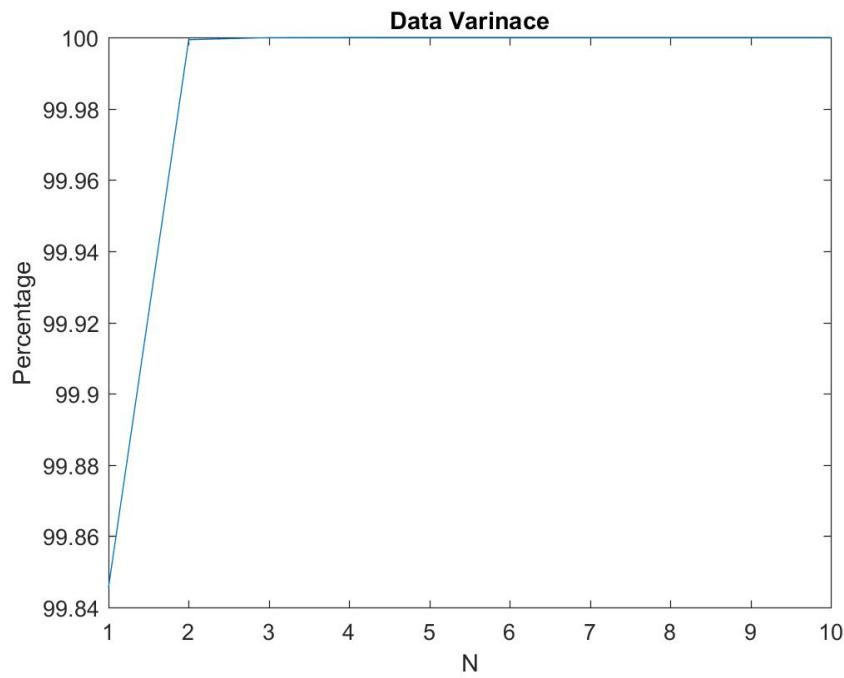


شکل 16: نقاط state های مختلف خواب برای subject 3

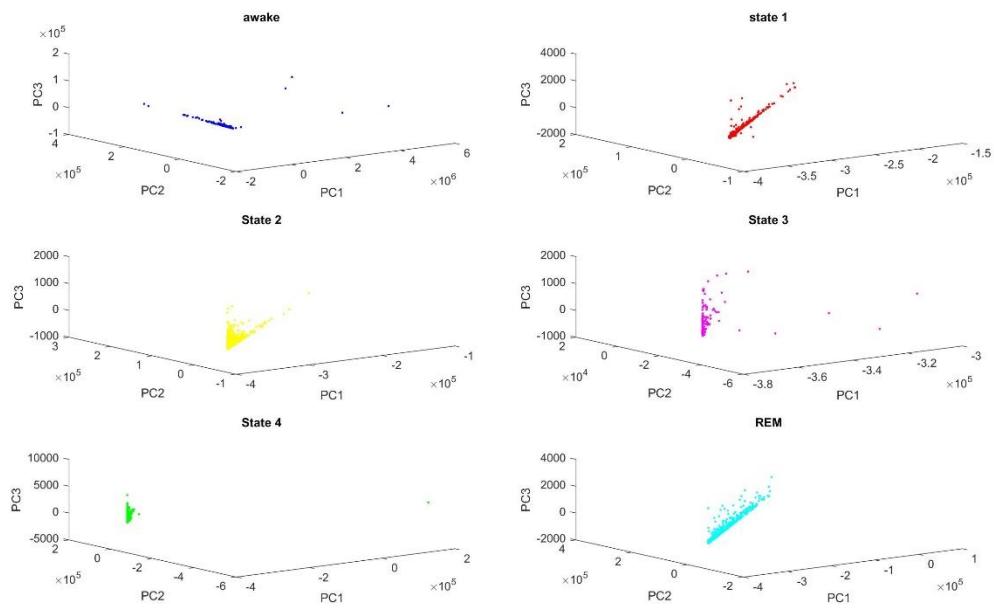


شکل ۱۷: نقاط *state* های مختلف خواب برای subject ۳

برای (ST7052Jo) subject ۴ داریم:

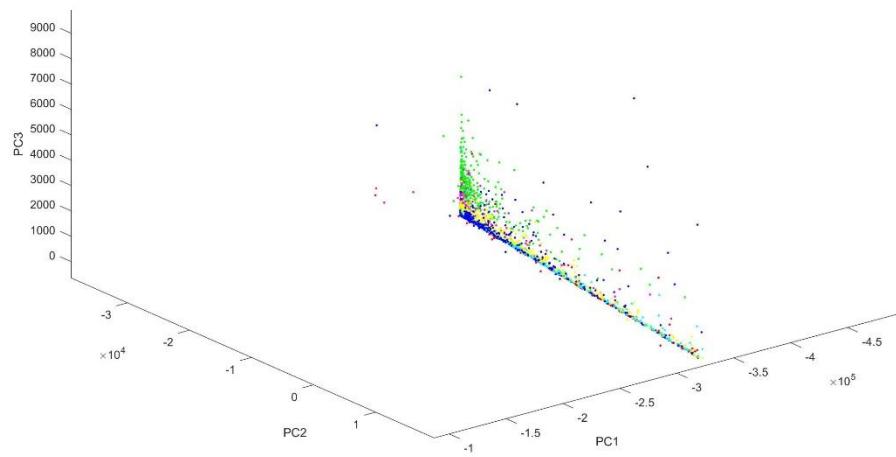


شکل ۱۸: نمودار تجمعی انرژی فضای بر حسب بردار های ویژه برای subject ۴



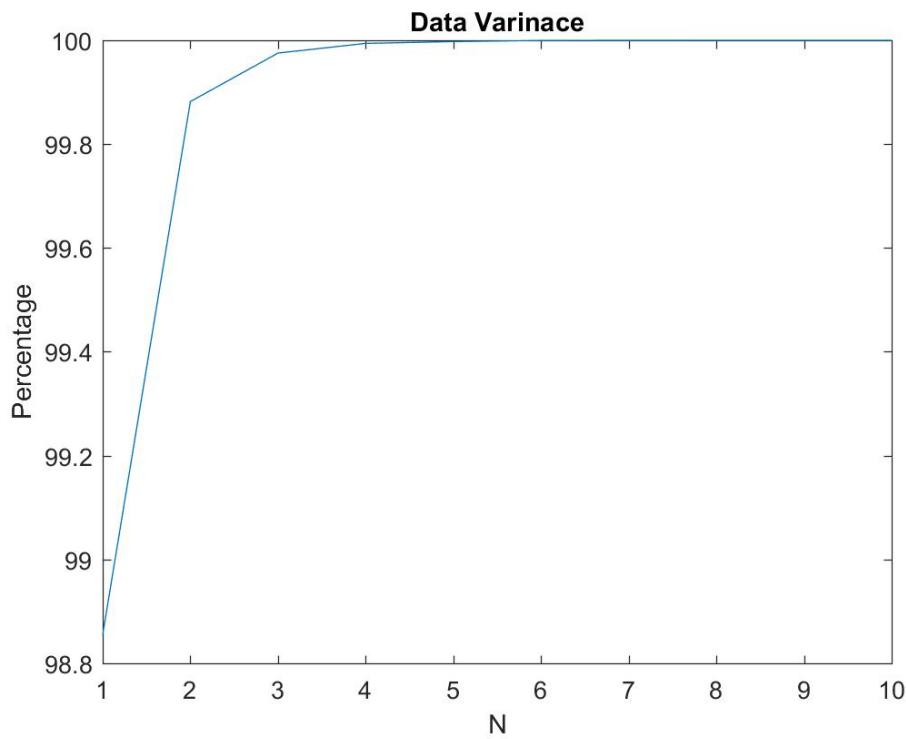
شکل 19: نقاط مختلف خواب برای subject 4

1
2
3
4

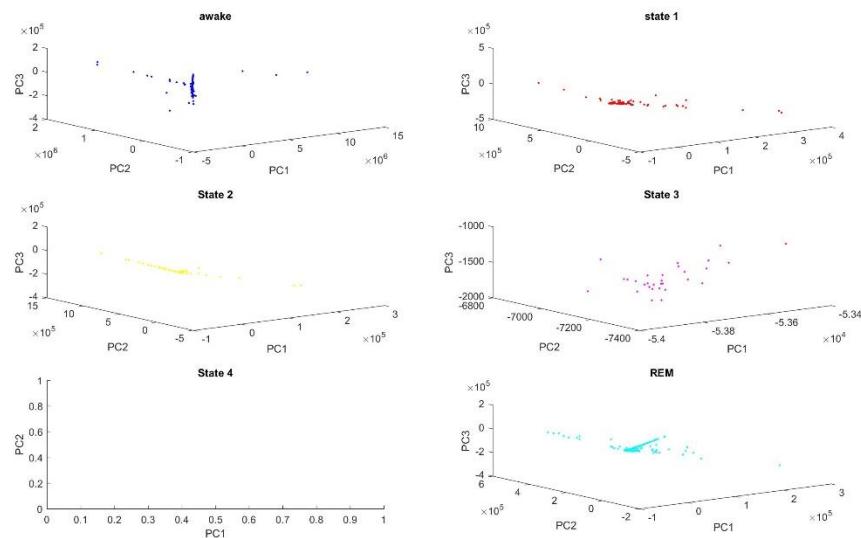


شکل 20: نقاط مختلف خواب برای subject 4

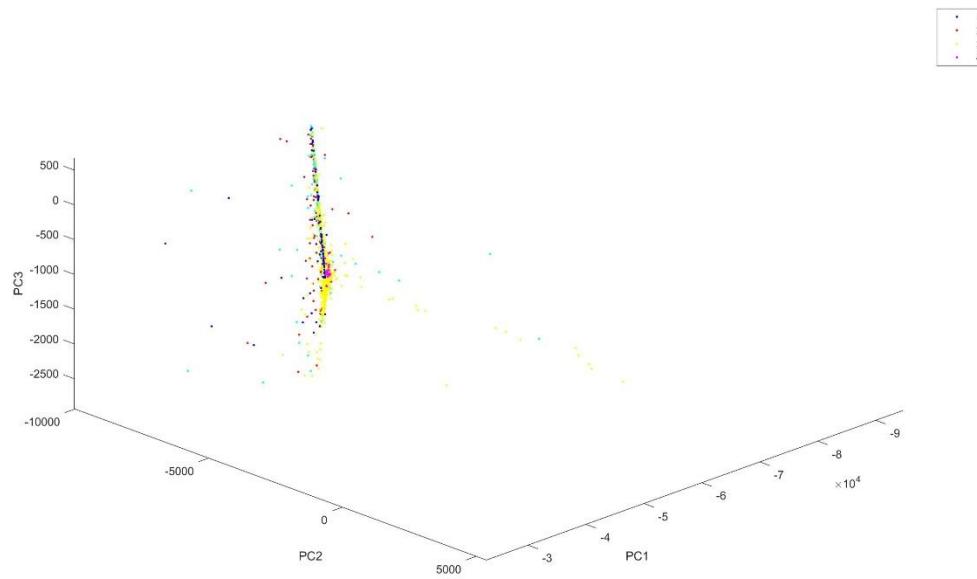
برای داریم (ST7061Jo) subject 5



شکل 21: نمودار تجمعی انرژی فضای بر حسب بردار های ویژه برای subject 5



شکل 22: نقاط state های مختلف خواب برای subject 5



شکل 23: نقاط مختلف خواب برای subject 5 state

QUESTION 7:

- نتیجه اول : معیار درست جداسازی state های خواب از هم توان متوسط در باند دلتای EEG Channel است .
- نتیجه دوم : خواب REM دارای توان متوسط بیشتری در سیگنال های EPG و EMG است .
- نتیجه سوم : در حالت بیداری ، نقاط از نظم کمتری برخوردارند و تحرکات رندوم موجبات این اتفاق را فراهم کرده اند .

Part 4 :

QUESTION 1:

ابندا با با توجه به بردار state ، حالت های 1 و 2 و 3 و 4 را از داده ها جدا می کنیم و سپس ماتریس X با label های subject state را برای ما انجام دهد . توجه کنید که این کار برای 2 انجام دادیم زیرا در سوالات قبل نتایج منطقی تری داد . خروجیتابع fitlm بدین صورت بود :

	Estimate	SE	tStat	pValue
(Intercept)	2.0121	0.040472	49.717	0
x1	0.00054139	2.7015e-05	20.04	6.2497e-82
x2	-0.0019015	0.0007344	-2.5892	0.0096866
x3	0.0029771	0.0011216	2.6543	0.008007
x4	-0.0010742	0.00052986	-2.0273	0.042759
x5	0.00024512	2.2542e-05	10.874	7.7404e-27
x6	0.021128	0.0016388	12.892	1.1561e-36
x7	-0.0025687	0.0030434	-0.84401	0.39876
x8	-0.10641	0.0060623	-17.553	1.6939e-64
x9	-1.9597e-08	3.4483e-07	-0.05683	0.95469
x10	-1.3589e-06	8.9057e-07	-1.5259	0.12718

Number of observations: 2124, Error degrees of freedom: 2113

Root Mean Squared Error: 0.645

R-squared: 0.537, Adjusted R-Squared 0.534

F-statistic vs. constant model: 245, p-value = 0

خروجی Estimate ، ضرایب هر یک از 10 feature را برای بدست آوردن عمق خواب به ما می دهد . با توجه به این خروجی بیشترین تاثیر را در عمق خواب توان باند بنا دارد . یعنی هر چه مولفه های فرکانس بالای سیگنال EEGOzCz کمتر شود عمق خواب افزایش می یابد . که این نتیجه با نتایج قبل کمی ناسازگاری دارد زیرا در بخش PCA هیچکدام از 3 مولفه های اول را باند بنا حساس نبودند . احسان اینجانب این است که به علت محدودیت های روش PCA (مثلاً عمود بودن محور ها) ممکن است کشیدگی در آن راستا بر اثر حذف شدن 7 بردار دیگر ، از بین رفته باشد لذا PCA نتوانسته باشد

جوابگو باشد اما وقتی که با regression کار میکنیم هر 10 مولفه را دخیل می‌کنیم . PCA صرفا جهت هایی با ماکزیمم کشیدگی را به ما میدهد و ممکن است در مسئله‌ی classification به ما کمک نکند . نتایج را از تاثیر گذار ترین به بی تاثیر ترین ردیف می‌کنیم .

Rank	Feature	Effect
1	EEGPzOz Beta Band	negative
2	EEGPzOz Theta Band	positive
3	EEGFpzCz Alpha Band	positive
4	EEGPzOz Alpha Band	negative
5	EEGFpzCz Theta Band	negative
6	EEGFpzCz Beta Band	negative
7	EEGPzOz Delta Band	positive
8	EEGFpzCz Delta Band	positive
9	EMGsubmental	Practically has no effect
10	EOGhorizontal	Practically has no effect

جدول شماره ۱ : نوع تاثیر feature ها در عمق خواب به ترتیب

خروجی p_value مقابله‌ی کدام از ضرایب حاصل اعمال hypothesis test را روی ضرایب است . این تست فرض را بر این می‌گذارد که این ضریب صفر است یعنی که این feature هیچگونه تاثیری در خروجی تابع ندارد (Null Hypothesis) . عدد p_value به ما می‌گوید که با فرض ۰ بودن ضریب چقدر احتمال دارد که ما این نتیجه را بگیریم . یعنی هر چقدر که p_value مقدار کمتری داشته باشد نتایج بدست آمده valid threshold را خواهد بود . اگر ما EEGFpzCz Alpha threshold را ۹۵ درصد قرار دهیم سه تا از ضرایب ما از این threshold عبور نکرده اند . یعنی ممکن است تاثیری که برای این سه feature بدست آورده EEGhorizontal و EMGsubmental و Band باشد . یعنی فرض را بر این می‌گذارد که همه‌ی این ضرایب ۰ باشد . عدد به دست آمده ۰ است یعنی عدد آن قدر کوچک بوده که قابل نمایش نبوده و سیستم آن را ۰ در نظر گرفته .

QUESTION ۲ :

معیار R^2 تعییر های متقاوی دارد . پس از ساختن مدلی برای پیش بینی داده های آینده ، R^2 به ما می‌گوید که چند درصد از تغییرات در خروجی تابع با تغییرات در ورودی تابع قابل توضیح هستند . یعنی اگر محور x ما به اندازه Δx تغییر کند محور y ما باید به اندازه Δy تغییر کند اما در واقعیت و بر اساس مشاهدات خروجی ما به اندازه Δy تغییر کرد . این معیار در واقع عیاری از $\frac{\Delta y - \Delta y'}{\Delta y}$ به ما می‌دهد . R^2 برخلاف باور غلط به ما نمی‌گوید که چند درصد از داده های ما با مدل قابل توجیه هستند . عبارت R^2 بدین صورت بدست می‌آید :

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i \quad SS_{\text{tot}} = \sum_i (y_i - \bar{y})^2 \quad SS_{\text{res}} = \sum_i (y_i - f_i)^2 = \sum_i e_i^2$$

$$R^2 \equiv 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$$

در بعضی از مسائل ، R^2 بالا لزوماً به منزله‌ی عالی بودن مدل نیست . گاهی اوقات بدین معناست که Overfitting رخ داده . مثلاً اگر نویزی حول داده های ما باشد R^2 قطعاً نباید کوچک باشد و صرفاً مدل به ما

محدوده‌ی خروجی را می‌دهد . در این پژوهش R^2 مقدار 0.537 دارد که به نسبت مقدار کمی است . اما دلایل بسیاری برای این موضوع وجود دارد که عبارت است از :

۱ _ داده‌های ما ماهیت گسته دارند و ما معیاری پیوسته برای توضیح آن‌ها ارائه دادیم . همین امر باعث افزایش R^2 شده .

۲ _ ما با فرض linear بودن نقاط ، خطی از آن رد می‌کنیم لذا در صورت برقرارنبوتن فرض به خطی ما افزوده می‌شود .

۳ _ داده‌های ما از کانال‌های EEG گرفته شده که خوب می‌دانیم نویز بالایی دارد لذا نقاط پرت به داده‌ها افزوده شده . نویز حول دیتا یکی از عوامل کاهش R^2 است .

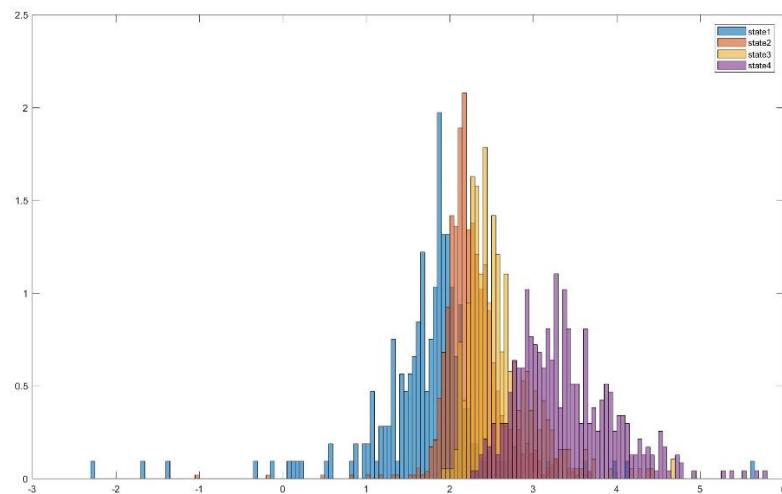
در سؤال‌های بعدی به طور کامل‌تر به توضیح و توجیه این معیار می‌پردازیم .

QUESTION 3 :

مدلی که در این سؤال بدست آورده‌یم صرفاً میزان عمق خواب را پیش‌بینی می‌کند . یعنی اگر ما مقدار 10 feature را به این مدل به عنوان ورودی دهیم ، خروجی یک معیار پیوسته به عنوان عمق خواب دریافت می‌کنیم . این مدل به پیش‌بینی قیمت نفت نزدیک‌تر است زیرا هر دو از جنس پیش‌بینی هستند .

QUESTION 4 :

بردار LinMode.Fitted مدل را روی داده‌های train ما اعمال می‌کند و به عنوان خروجی می‌دهد . با استفاده از بردار state ، اندیس عمق‌های مختلف را بدست می‌آوریم و از روی بردار LinMode.Fitted آن‌ها را استخراج می‌کنیم و در 4 دسته قرار می‌دهیم . سپس هیستوگرام این 4 دسته را می‌کشیم . شکل بدست آمده به صورت زیر است :

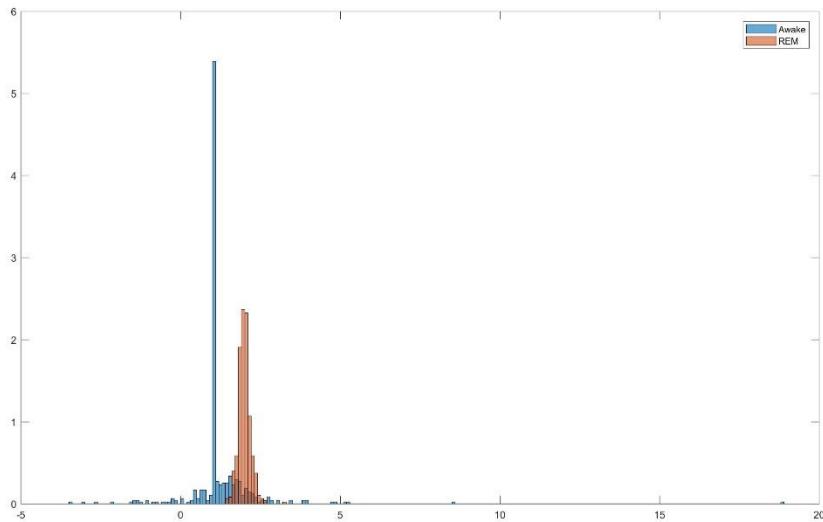


شکل 24 : هیستوگرام مقدار پیش‌بینی شده توسط مدل برای state‌های ۱ تا ۴ خواب NREM

همانطور که مشاهده می‌شود قله‌های این هیستوگرام تفاوت عمق‌های خواب را تقریباً نشان می‌دهند . همچنین Overlap های زیادی نیز دیده می‌شود که ناکارآمدی مدل ما مشخص می‌شود . این Overlap‌ها ممکن است با روش‌هایی Minimum شود . مثلاً می‌توان با روش‌هایی مثل انتگرال Kullback_Liebler می‌توان مدلی را انتخاب کرد که تفاوت این توزیع‌ها را ماقزیم کرد تا دسته‌بندی با راندمان بالاتری صورت گیرد .

QUESTION 4 :

حال همان کاری که در بالا کردیم را برای state های REM و AWAKE انجام می دهیم با این تفاوت که این داده ها نشده اند و داده های test هستند. سپس روی این داده ها تابع LinMode.predict را اجرا می کنیم. اعداد بدست آمده را برای هر دو حالت Histogram میکنیم.



شکل 25: هیستوگرام مقدار پیش بینی شده توسط مدل برای state های REM و AWAKE

باید توجه داشته باشیم که مدل بر روی داده های state های 1 تا 4 train شده است. و ما های REM و awake را می خواهیم با این مدل پیش بینی کنیم . بر اساس این مدل عمق خواب REM همانطور که انتظار میرفت بیشتر از حالت awake است . همچنین پخش شدگی حالت awake قابل توجه است که قبل توضیح دادیم . چون حرکات بدن و سر تقریبا رندوم می باشد لذا از توزیع متمرکزی برخوردار نیست . با توجه به همین Histogram ها برای سایر حالت های دیگر متوجه می شویم که در بعضی از موارد توزیع REM با توزیع awake بسیار شبیه است و روی هم افتاده اند (به غیر از یک سری نقاط پرت در حالت awake) . دلیل این اتفاق این است که حالت REM آخرین state قبل از بیداری است لذا بسیار شبیه حالت بیداری است . (در بخش 3 سؤال 4 توضیح داده شده است)

QUESTION 6 :

: 1 (ST7011Jo)

	Estimate	SE	tStat	pValue
(Intercept)	1.9191	0.029784	64.434	0
x1	4.5658e-05	2.4348e-05	1.8752	0.060886
x2	0.0058625	0.00127	4.6162	4.1249e-06
x3	0.0037556	0.0021821	1.7211	0.085361
x4	-0.0048341	0.00097785	-4.9436	8.2285e-07
x5	0.00026923	6.5587e-05	4.1049	4.1876e-05
x6	0.043019	0.0036789	11.693	1.0177e-30
x7	-0.028517	0.0070999	-4.0165	6.0982e-05
x8	-0.061927	0.008129	-7.618	3.7506e-14
x9	-4.4882e-06	1.3119e-06	-3.4212	0.00063438
x10	-2.0801e-05	1.1459e-05	-1.8153	0.069613

Number of observations: 2292, Error degrees of freedom: 2281

Root Mean Squared Error: 0.579

R-squared: 0.289, Adjusted R-Squared 0.286

F-statistic vs. constant model: 92.9, p-value = 3.54e-161

: 3(ST7041Jo)

	Estimate	SE	tStat	pValue
(Intercept)	2.0366	0.025684	79.294	0
x1	0.00044791	2.0742e-05	21.594	5.9537e-93
x2	0.0070614	0.00076647	9.2129	7.9187e-20
x3	-0.0065562	0.00090736	-7.2256	7.1141e-13
x4	-0.009952	0.001134	-8.7759	3.6129e-18
x5	-1.9077e-07	5.9907e-08	-3.1844	0.0014734
x6	-1.272e-06	6.0164e-07	-2.1143	0.034617
x7	1.7555e-06	7.7787e-07	2.2568	0.024129
x8	5.5382e-07	1.1035e-06	0.50185	0.61583
x9	-1.3623e-05	9.9125e-07	-13.743	4.2298e-41
x10	5.6499e-07	1.9204e-07	2.942	0.0032991

Number of observations: 1971, Error degrees of freedom: 1960

Root Mean Squared Error: 0.551

R-squared: 0.481, Adjusted R-Squared 0.479

F-statistic vs. constant model: 182, p-value = 6.8e-271

: 4(ST7052Jo)

	Estimate	SE	tStat	pValue
(Intercept)	1.4516	0.02759	52.614	0
x1	0.00038057	2.8302e-05	13.447	1.4238e-39
x2	0.0042348	0.0010361	4.0873	4.5324e-05
x3	0.001241	0.0014934	0.83099	0.40608
x4	-0.0015239	0.00075152	-2.0278	0.042712
x5	0.0013931	8.8797e-05	15.689	1.7427e-52
x6	0.039408	0.0019855	19.847	2.3506e-80
x7	-0.0072397	0.0042071	-1.7208	0.085432
x8	-0.0095019	0.0029044	-3.2715	0.0010874
x9	-4.7826e-06	3.2339e-07	-14.789	4.1279e-47
x10	-4.5372e-07	6.8246e-07	-0.66484	0.50623

Number of observations: 2070, Error degrees of freedom: 2059

Root Mean Squared Error: 0.495

R-squared: 0.734, Adjusted R-Squared 0.733

F-statistic vs. constant model: 568, p-value = 0

: 5(ST7061Jo)

	Estimate	SE	tStat	pValue
(Intercept)	1.7768	0.013913	127.71	0
x1	0.00022392	4.4664e-05	5.0134	5.806e-07
x2	0.0046931	0.00066591	7.0476	2.4757e-12
x3	0.0024176	0.00063247	3.8224	0.00013607
x4	-0.0033957	0.00033763	-10.058	2.9135e-23
x5	-2.3597e-07	1.8643e-07	-1.2658	0.20574
x6	3.2824e-06	5.2106e-06	0.62996	0.52879
x7	1.2281e-05	1.0758e-05	1.1416	0.25377
x8	-1.8557e-05	8.3714e-06	-2.2167	0.02675
x9	-2.617e-05	1.8022e-06	-14.521	1.4913e-45
x10	-1.4085e-06	2.4435e-07	-5.7645	9.4318e-09

Number of observations: 2064, Error degrees of freedom: 2053

Root Mean Squared Error: 0.313

R-squared: 0.254, Adjusted R-Squared 0.25

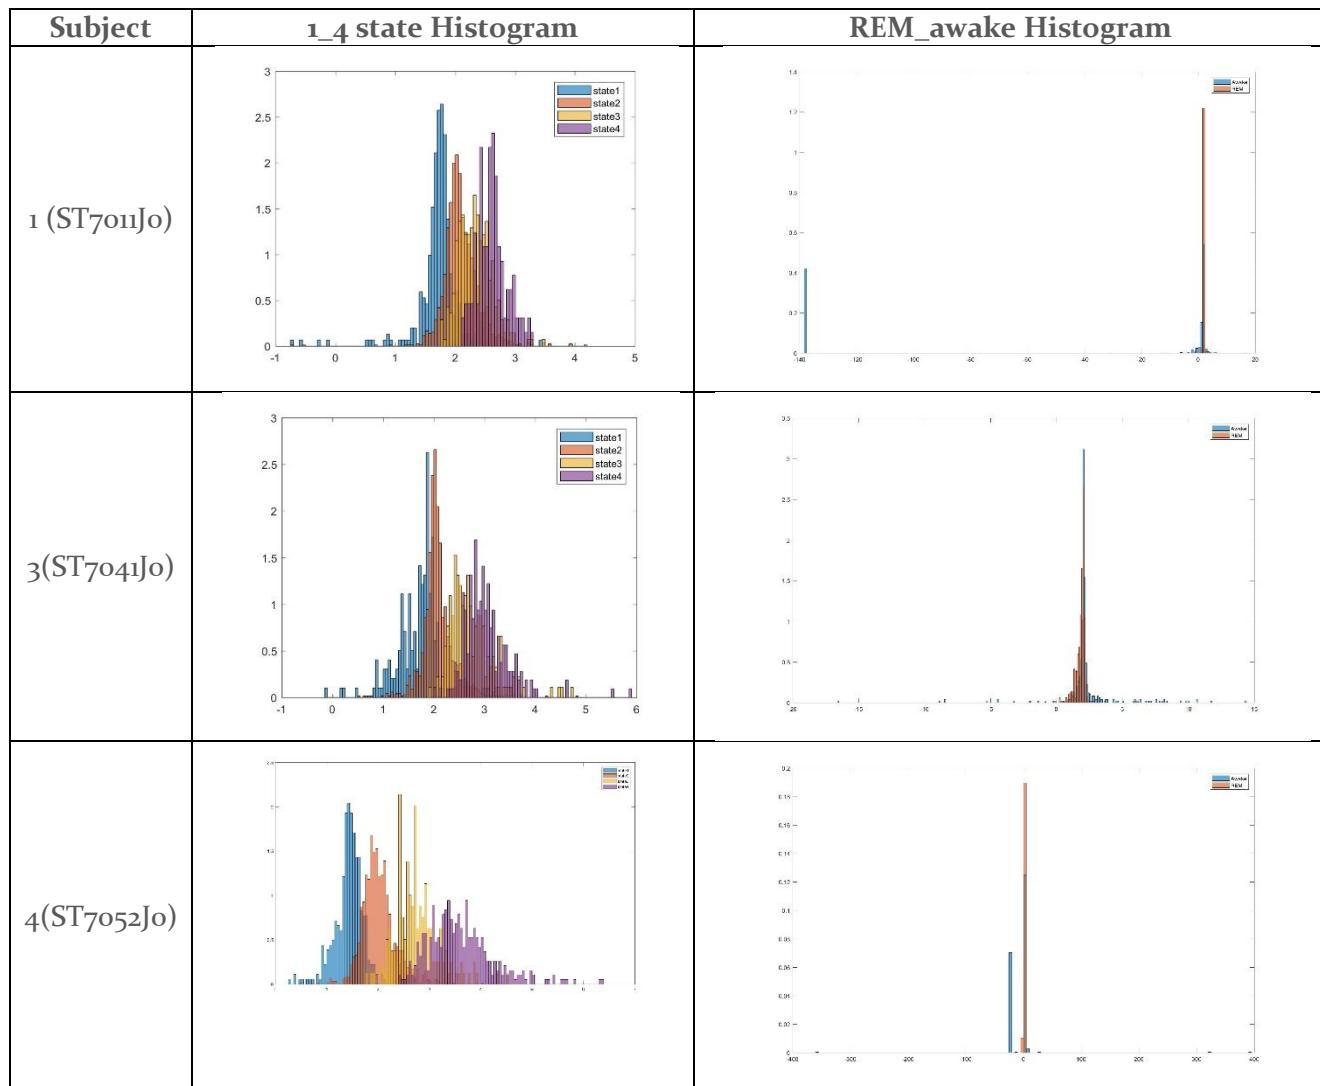
F-statistic vs. constant model: 69.9, p-value = 4.9e-123

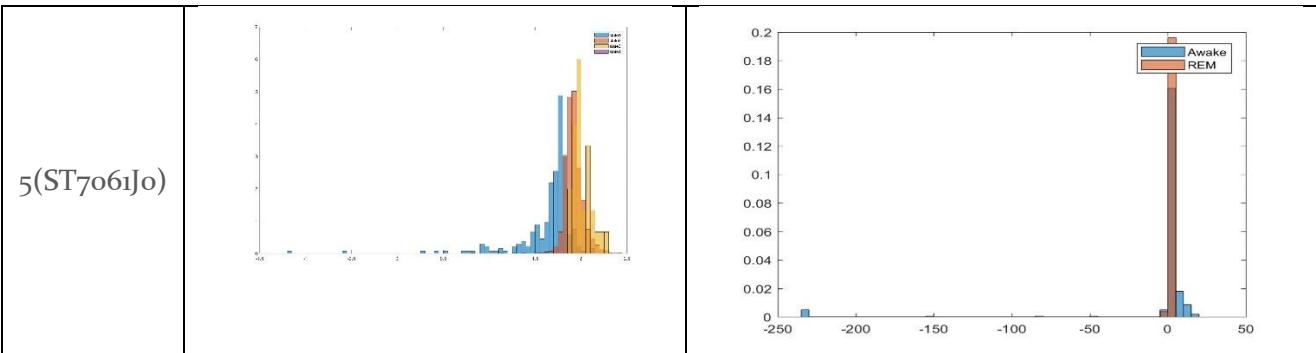
با تحلیل و مقایسه ضرایب به موارد مهم زیر می پردازیم :

1_ نکته‌ی مهمی که در تحلیل این ضرایب برای افراد مختلف بدست می‌آید این است که یک مؤلفه در اکثر مواقع (حداقل 4 مورد از 5 مورد) به یک شکل عمل می‌کند یعنی یا تاثیر منفی یا تاثیر مثبت . این موضوع برای یک مؤلفه که FPZOzCz Delta Band Power می‌باشد صادق نبود . یعنی برای نیمی از افراد تاثیر مثبت و برای نیمی دیگر تاثیر منفی داشت .

2_ برای 3 نفر از 5 نفر مؤلفه های EEGPzOz Theta Band و EEGPzOz Beta Band بیشترین تاثیر را با اختلاف زیاد از بقیه داشتند .
3_ برای همان 3 نفر ، مؤلفه های EMGSubmental و EOGHorizontal عملا هیچ تاثیری در عمق خواب نداشتند.

4_ هر سه p_value اعداد بسیار بسیار کوچکی هستند .





جدول ۲ Histogram های دیگر Subject های

Part 5 :

سوال اول :

در این قسمت قصد داریم با اعمال روش linear SVM کلاس بندی برای State های ۱ تا ۴ تشکیل دهیم تا با داشتن ماتریس ویژگی های x تشخیص دهد فرد در هر لحظه در کدام State قرار دارد. برای این منظور،تابع Trainclassifier را تشکیل می دهیم. ورودی این تابع trainingData ، از ۱۱ ستون تشکیل می شود که ۱۰ ستون اول آن مربوط به ۱۰ ویژگی به دست آمده در قسمت های پیشین (predictors) و ستون آخر مربوط به بردار State می باشد. (response) این تابع دو خروجی به نام های trainedClassifier و validationAccuracy خواهد بود که توضیح هر کدام در زیر آمده است:

تابع Struct می باشد که شامل field هایی درباره ی TrainedClassifier است که دلخواه طراح می باشد. اما این خروجی باید شامل تابع TrainedClassifier.predictFcn باشد که با گرفتن ماتریس ورودی X ، بردار State متناظر با آن را پیش بینی کند.

تابع validationAccuracy : باید دقت Classification را به صورت درصد بیان کند. حال تابع شرح داده شده را برای سایجکت اول پیاده سازی کنید و نتیجه را بیان کنید. آیا می توان از کلاس بندی آموزش داده شده توسط سایجکت اول برای سایجکت های دیگر استفاده کرد؟ پاسخ:

تابع trainClassifier به همراه کامنت گذاری مناسب و قطعه کدی در main برای بررسی نتایج نوشته شده است. برای آزمودن عملکرد کلاس بندی ابتدا با داده های سایجکت اول آن را آموزش دادیم و سپس روی ماتریس x همان داده های اول، آزمایش کردیم که با استفاده از confusionmat ماتریس زیر به دست می آید:

38	265	0	0
11	1558	0	12
0	239	0	40
0	62	0	67

سطر های این ماتریس مربوط به true class و ستون های آن مربوط به predicted class می باشد.

بنابراین هر چه تعداد مشاهدات روی قطر اصلی بزرگتر باشد، مدل بهتری خواهیم داشت. همان طور که ملاحظه می شود در این حالت به کلی اشتباه تشخیص داده شده است. State3

حال کلاس بندی را برای سایجکت دوم آزمایش می کنیم و به ماتریس زیر می رسیم:

54	159	0	0
26	1027	0	6
0	362	0	19
0	209	14	248

همان طور که ملاحظه می شود این کلاس بندی برای ساچکت دوم نیز جواب داد. یعنی state خواب هر فردی را می توان تنها با داشتن ماتریس X در هر لحظه فهمید.

سوال: حال تاثیر PCA را بر روی کلاس بندی خود امتحان کنید. validationAccuracy چه تغییری می کند؟

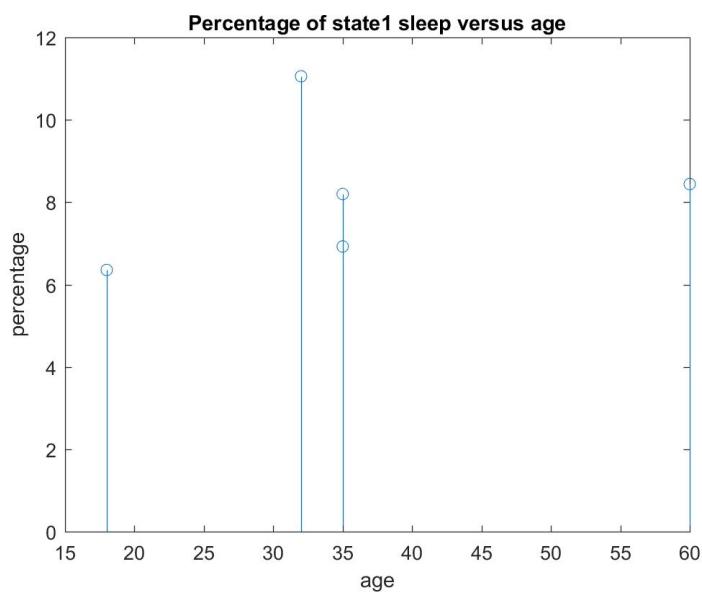
پاسخ: تابع trainClassifier2 کلاس بندی به همراه PCA بر روی ماتریس X است. در این حالت کاهش می یابد و confusion matrix به صورت زیر می شود که از دقت پایین تری نسبت به حالت قبل برخوردار است:

10	293	0	0
5	1576	0	0
0	279	0	0
0	129	0	0

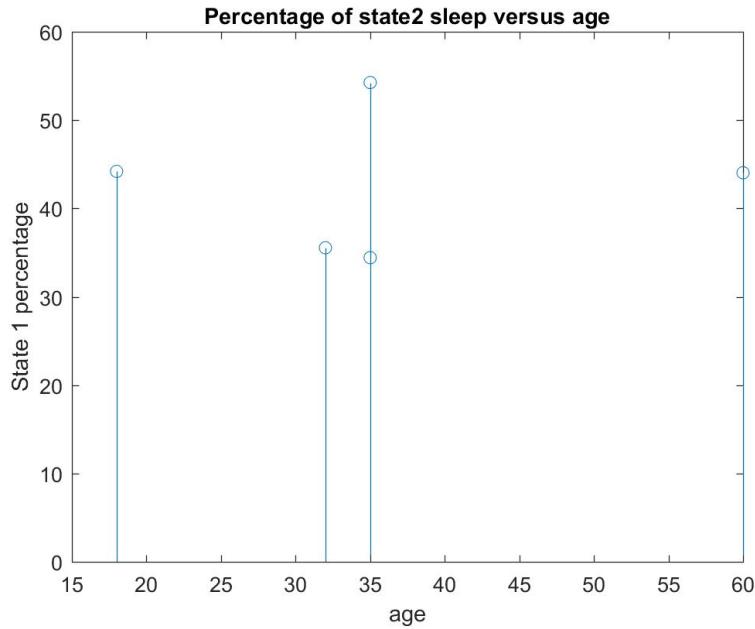
استیت 4 و 3 به کلی تشخیص داده نمی شوند! باز هم به آن نکته پی می برمی که PCA لزوماً بهبودی در مسئله ای classificaton ایجاد نمی کند.

سوال دوم :

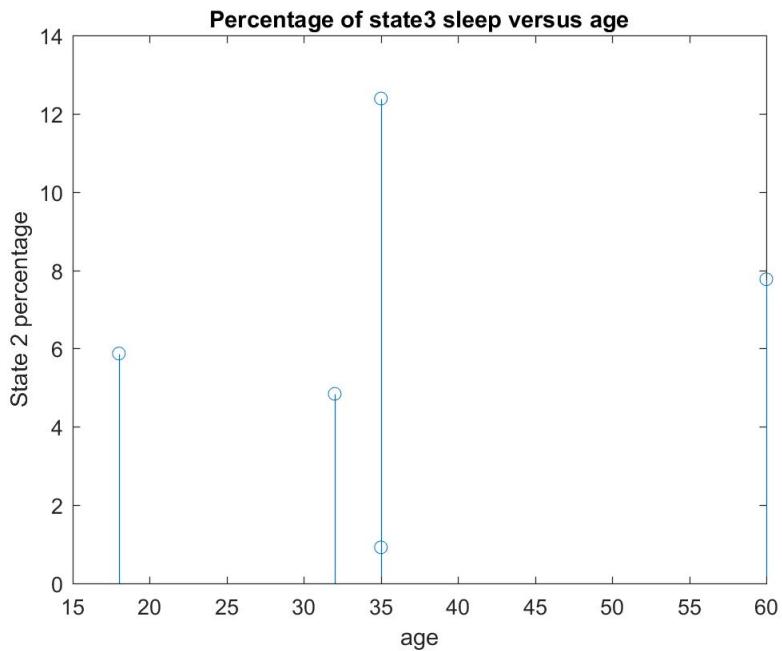
در این بخش می خواهیم بینیم به طور حدودی چند درصد از خواب را state های مختلف خواب تشکیل می دهد و اینکه آیا سن با میزان زمان state های مختلف ارتباطی دارد. برای این کار می بایست از داده های تمام 24 نفر استفاده کنیم تا نتایج اعتبار داشته باشد اما به دلیل حجم بالای اطلاعات و اینکه داده های hypnogram مانند داده های پروژه ساده سازی نشده بودند به همین 5 ساچکت بسته کردیم. این نتایج فاقد هرگونه اعتبار آماری است و صرفاً بررسی نادقيق بر روی نمونه های محدود است و هدف بدست آوردن کمی دید درباره ای موضوع مطرح شده است. با استفاده از تعداد state ها در بردار state نمودار های زیر را بدست می آوریم.



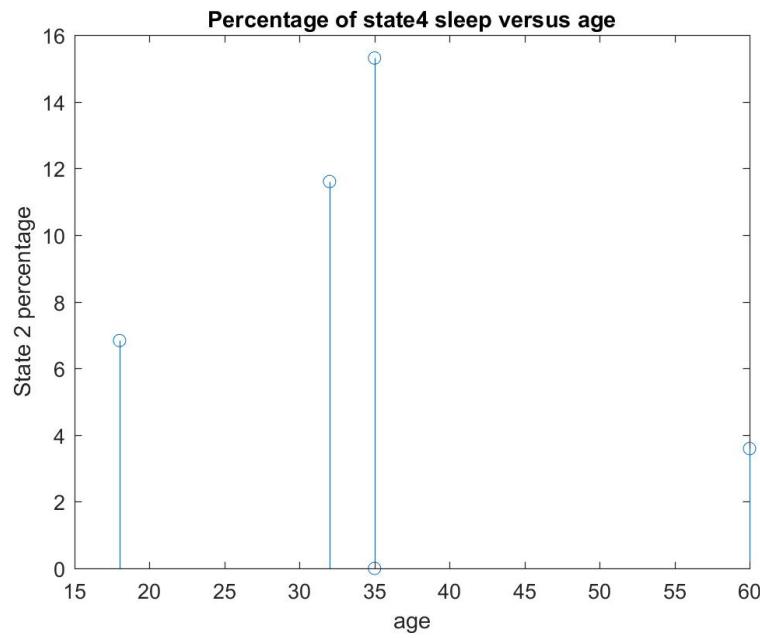
شکل 26: درصد 1 در خواب بر حسب سن برای subject های 1 تا 5



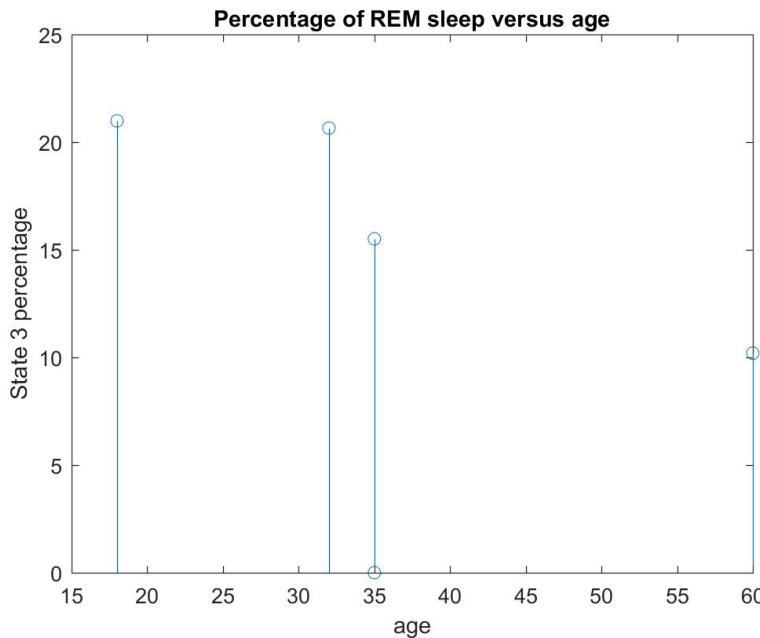
شکل 27: درصد 2 در خواب بر حسب سن برای subject های ۱ تا ۵



شکل 28: درصد 3 در خواب بر حسب سن برای subject های ۱ تا ۵



شکل 29: درصد 4 در خواب بر حسب سن برای subject 5 های تا 5



شکل 30: درصد REM در خواب بر حسب سن برای subject 5 های تا 5

مشاهدات را در جدول های پایین دسته بندی کردیم :

State	Mean Percentage
1	8.1947 %
2	42.4914 %
3	6.3590 %
4	7.4693 %
REM	13.4685%

جدول 3: میانگین درصد state های خواب برای subject های 1_5

همانطور که مشاهده می شود به طور میانگین بیشتر طول خواب در state 2 گزرانده می شود و پس از آن در REM .

همچنین مشاهده می کنیم که بالا رفتن سن ، تغییر محسوسی در State ها 1 تا 3 ایجاد نمیشود اما میزان state های 4 و REM تغییر می کنند . این دو در واقع State هایی هستند که کیفیت خواب را مشخص می کنند . پس می توان نتیجه گرفت که کیفیت خواب با افزایش سن کاهش می یابد . همچنین در همه ی نمودار ها مد برای سنین حول 30 سال است .

Appendix : Main Code and the Results

Contents

- [Part 3](#)
- [Applying PCA and plotting the variance graph](#)
- [Plotting the points seperately](#)
- [Part 4](#)
- [Fitting a linear model on data](#)
- [Plotting histogram on states 1_4](#)
- [Plotting histogram on REM and awake states](#)
- [Part 5 _ SVM on raw data](#)
- [SVM on data after applying PCA](#)
- [age and states](#)

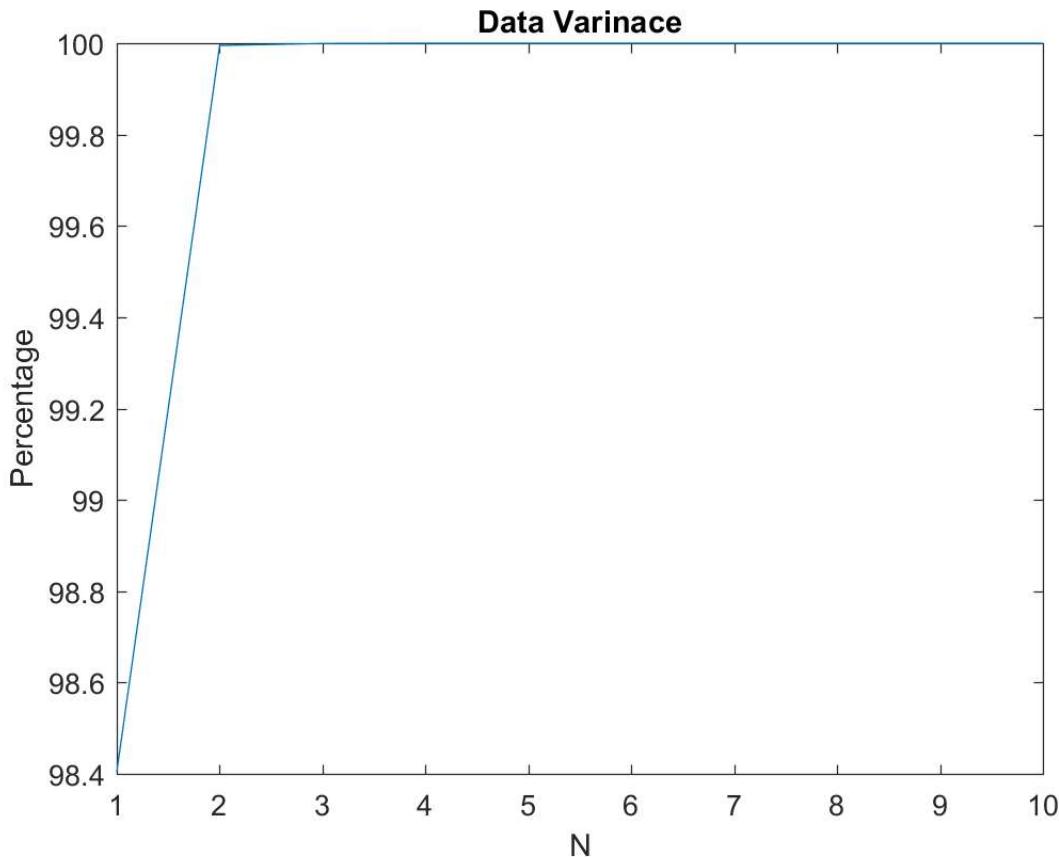
```
[t state X] = FeatureExtraction ('C:\Users\Alireza\Desktop\Project2\Data\ST7022J0-PSG.edf';
,'C:\Users\Alireza\Desktop\Project2\Data\ST7022JM-Hypnogram_annotations.txt') ;
```

Step 1 of 2: Reading requested records. (This may take a few minutes.)...
Step 2 of 2: Parsing data...

Part 3

Applying PCA and plotting the variance graph

```
[coeff,score,latent] = pca(X) ; % PCA on X matrix
Percentage = zeros (1,10) ;
Totall_Variance = sum (latent) ;
for i=1:10
    Percentage(i) = (sum(latent(1:i))/Totall_Variance) * 100 ; % Showing what percentage of
    % the space being described by the eigenvectors
end
n = 1:10 ;
figure
plot (n , Percentage)
title ('Data Varinace')
xlabel ('N')
ylabel ('Percentage')
```



```

X1 = score (:,1) ;
X2 = score (:,2) ;
X3 = score (:,3) ;

% finding state indices

zero_state_ind = find (state == 0) ;
one_state_ind = find (state == 1) ;
two_state_ind = find (state == 2) ;
three_state_ind = find (state == 3) ;
four_state_ind = find (state == 4) ;
five_state_ind = find (state == 6) ;

% coeffficients of state 0

awake1 = X1(zero_state_ind) ;
awake2 = X2(zero_state_ind) ;
awake3 = X3(zero_state_ind) ;

% coeffficients of state 1

FirstState1 = X1(one_state_ind) ;
FirstState2 = X2(one_state_ind) ;
FirstState3 = X3(one_state_ind) ;

% coeffficients of state 2

SecondState1 = X1(two_state_ind) ;
SecondState2 = X2(two_state_ind) ;

```

```

SecondState3 = X3(two_state_ind) ;

% coefficitions of state 3

thirdState1 = X1(three_state_ind) ;
thirdState2 = X2(three_state_ind) ;
thirdState3 = X3(three_state_ind) ;

% coefficitions of state 4

fourthState1 = X1(four_state_ind) ;
fourthState2 = X2(four_state_ind) ;
fourthState3 = X3(four_state_ind) ;

% coefficitions of state 5

REM1 = X1(five_state_ind) ;
REM2 = X2(five_state_ind) ;
REM3 = X3(five_state_ind) ;

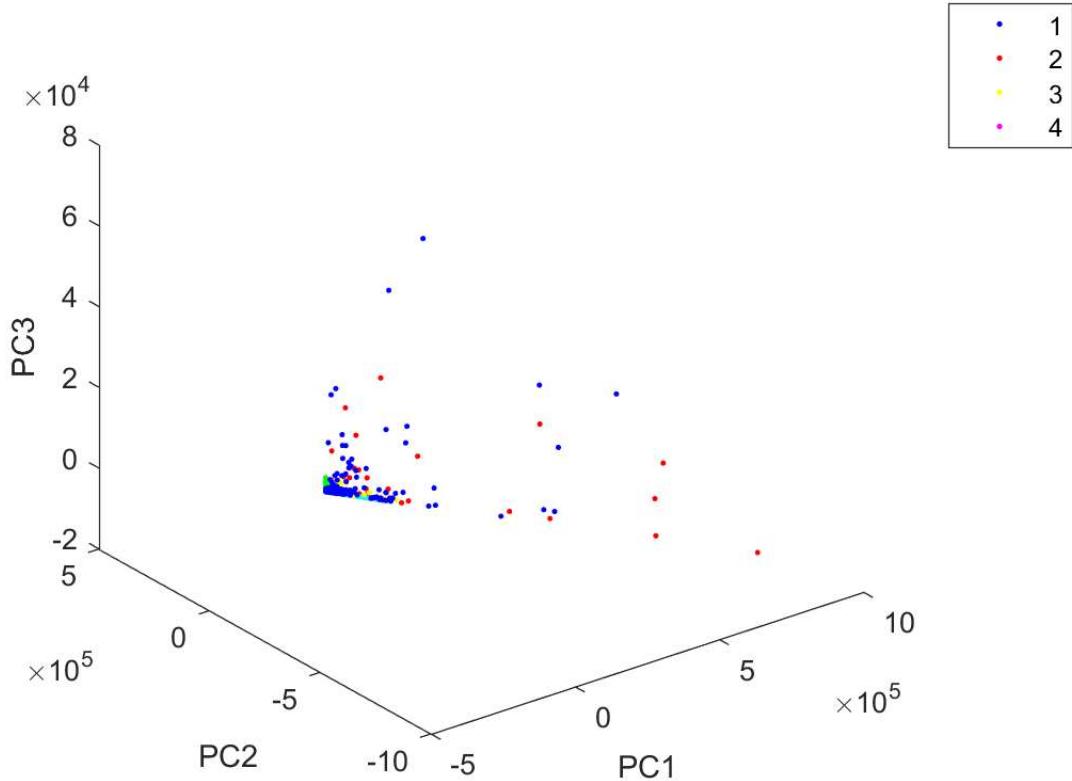
% Plotting the points

figure
plot3 (awake1, awake2 , awake3 , '.', 'color' , 'b')
hold on
plot3 (FirstState1 , FirstState2 , FirstState3 , '.', 'color' , 'r')
hold on
plot3 (SecondState1 , SecondState2 , SecondState3 , '.', 'color' , 'y')
hold on
plot3 (thirdState1 , thirdState2 , thirdState3 , '.', 'color' , 'm')
hold on
plot3 (fourthState1, fourthState2 , fourthState3 , '.', 'color' , 'g')
hold on
plot3 (REM1 , REM2 , REM3 , '.', 'color' , 'c')

legend ('1','2','3','4')

xlabel ('PC1')
ylabel ('PC2')
zlabel ('PC3')

```



Plotting the points separately

```

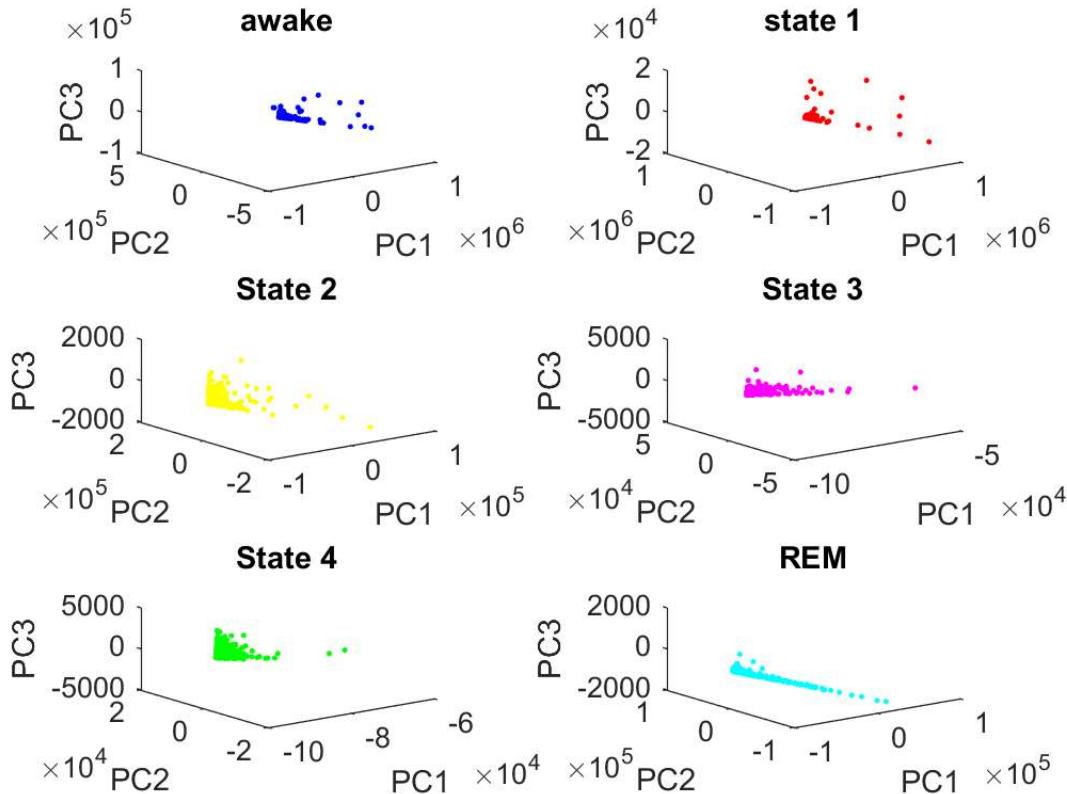
figure
subplot(3,2,1)
plot3 (awake1, awake2 , awake3 , '.', 'color' , 'b')
title ('awake')
xlabel ('PC1')
ylabel ('PC2')
zlabel ('PC3')
subplot(3,2,2)
plot3 (FirstState1 , FirstState2 , FirstState3 , '.', 'color' , 'r')
title ('state 1')
xlabel ('PC1')
ylabel ('PC2')
zlabel ('PC3')
subplot(3,2,3)
plot3 (SecondState1 , SecondState2 , SecondState3 , '.', 'color' , 'y')
title ('State 2')
xlabel ('PC1')
ylabel ('PC2')
zlabel ('PC3')
subplot(3,2,4)
plot3 (thirdState1 , thirdState2 , thirdState3 , '.', 'color' , 'm')
title ('State 3')
xlabel ('PC1')
ylabel ('PC2')
zlabel ('PC3')
subplot(3,2,5)
plot3 (fourthState1, fourthState2 , fourthState3 , '.', 'color' , 'g')

```

```

title ('State 4')
xlabel ('PC1')
ylabel ('PC2')
zlabel ('PC3')
subplot(3,2,6)
plot3 (REM1 , REM2 , REM3 , '.', 'color' , 'c')
title ('REM')
xlabel ('PC1')
ylabel ('PC2')
zlabel ('PC3')

```



Part 4

Fitting a linear model on data

```

x = X ;
Wake_Rem_index = find(state==0|state==6) ; % separating the REM and awake data
x(Wake_Rem_index,:) = [] ; % deleting the REM and awake data
y = (state)' ;
y(Wake_Rem_index,:) = [] ;
LinMod = fitlm (x,y) % Regression Model

```

LinMod =

Linear regression model:
 $y \sim 1 + x_1 + x_2 + x_3 + x_4 + x_5 + x_6 + x_7 + x_8 + x_9 + x_{10}$

Estimated Coefficients:

	Estimate	SE	tStat	pValue
(Intercept)	2.0121	0.040472	49.717	0
x1	0.00054139	2.7015e-05	20.04	6.2497e-82
x2	-0.0019015	0.0007344	-2.5892	0.0096866
x3	0.0029771	0.0011216	2.6543	0.008007
x4	-0.0010742	0.00052986	-2.0273	0.042759
x5	0.00024512	2.2542e-05	10.874	7.7404e-27
x6	0.021128	0.0016388	12.892	1.1561e-36
x7	-0.0025687	0.0030434	-0.84401	0.39876
x8	-0.10641	0.0060623	-17.553	1.6939e-64
x9	-1.9597e-08	3.4483e-07	-0.05683	0.95469
x10	-1.3589e-06	8.9057e-07	-1.5259	0.12718

Number of observations: 2124, Error degrees of freedom: 2113

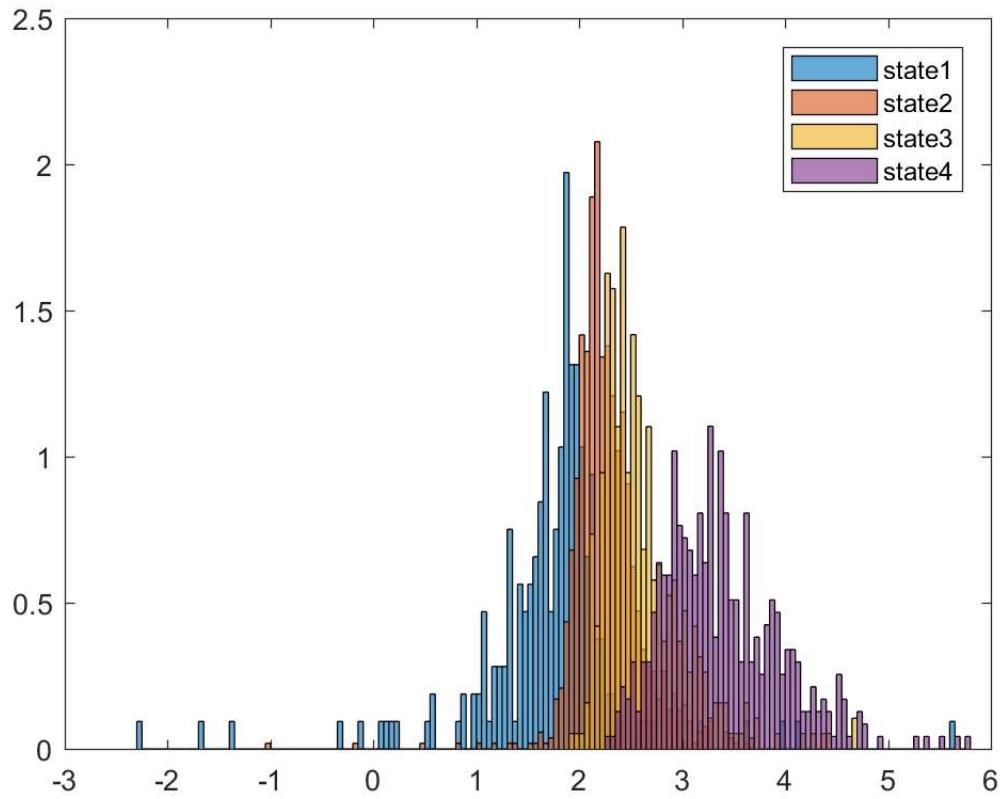
Root Mean Squared Error: 0.645

R-squared: 0.537, Adjusted R-Squared 0.534

F-statistic vs. constant model: 245, p-value = 0

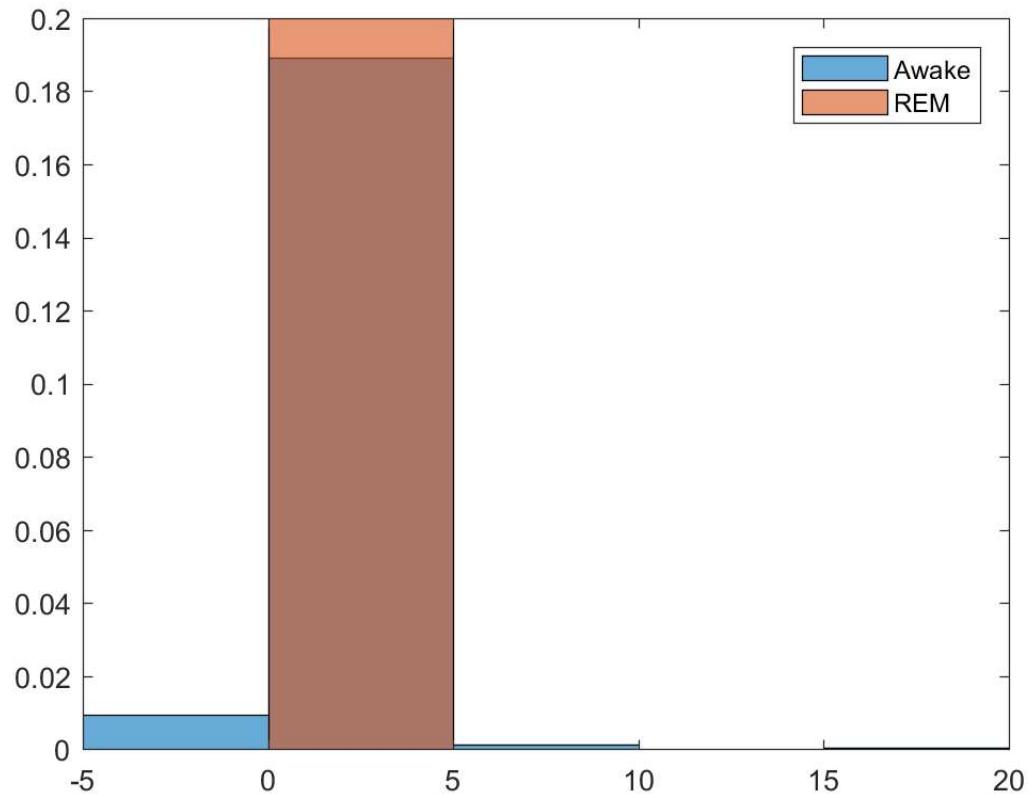
Plotting histogram on states 1_4

```
figure
histogram(LinMod.Fitted(find(y==1)), 'Normalization', 'pdf', 'BinWidth', 0.05)
hold on
histogram(LinMod.Fitted(find(y==2)), 'Normalization', 'pdf', 'BinWidth', 0.05)
hold on
histogram(LinMod.Fitted(find(y==3)), 'Normalization', 'pdf', 'BinWidth', 0.05)
hold on
histogram(LinMod.Fitted(find(y==4)), 'Normalization', 'pdf', 'BinWidth', 0.05)
legend ('state1','state2','state3', 'state4')
```



Plotting histogram on REM and awake states

```
figure
histogram(LinMod.predict(X(find(state==0),:)), 'Normalization', 'pdf', 'BinWidth', 5)
hold on
histogram(LinMod.predict(X(find(state==6),:)), 'Normalization', 'pdf', 'BinWidth', 5)
legend ('Awake' , 'REM')
```



Part 5 _ SVM on raw data

```
[t2 ,state2 ,X2] = FeatureExtraction ('C:\Users\Alireza\Desktop\Project2\Data\ST7022JM-PSG.edf','C:\Users\Alireza\Desktop\Project2\Data\ST7022JM-Hypnogram_annotations.txt') ;
Xc=[x y]; %training data
[trained,v1]=trainClassifier(Xc);
testclassifier=trained.predictFcn(x); % prediction of classifier
x2 = X2 ;
Wake_Rem_index = find(state==0|state==6) ;
x2(Wake_Rem_index,:)= [] ;
y2 = (state2)' ;
y2(Wake_Rem_index,:)= [] ;
a=trained.predictFcn(x2);
ca=confusionmat(y2,a)
c=confusionmat(y,testclassifier)
```

Step 1 of 2: Reading requested records. (This may take a few minutes.)...
Step 2 of 2: Parsing data...

ca =

115	97	1	0
17	992	45	5
0	226	120	35
0	12	52	407

```
c =
```

115	97	1	0
17	992	45	5
0	226	120	35
0	12	52	407

SVM on data after applying PCA

```
[trained2,v2]=trainClassifier2(Xc);
testclassifier2=trained2.predictFcn(x) ;
c2=confusionmat(y,testclassifier2)
```

```
c2 =
```

28	181	0	4
6	1009	2	42
0	314	0	67
0	100	1	370

age and states

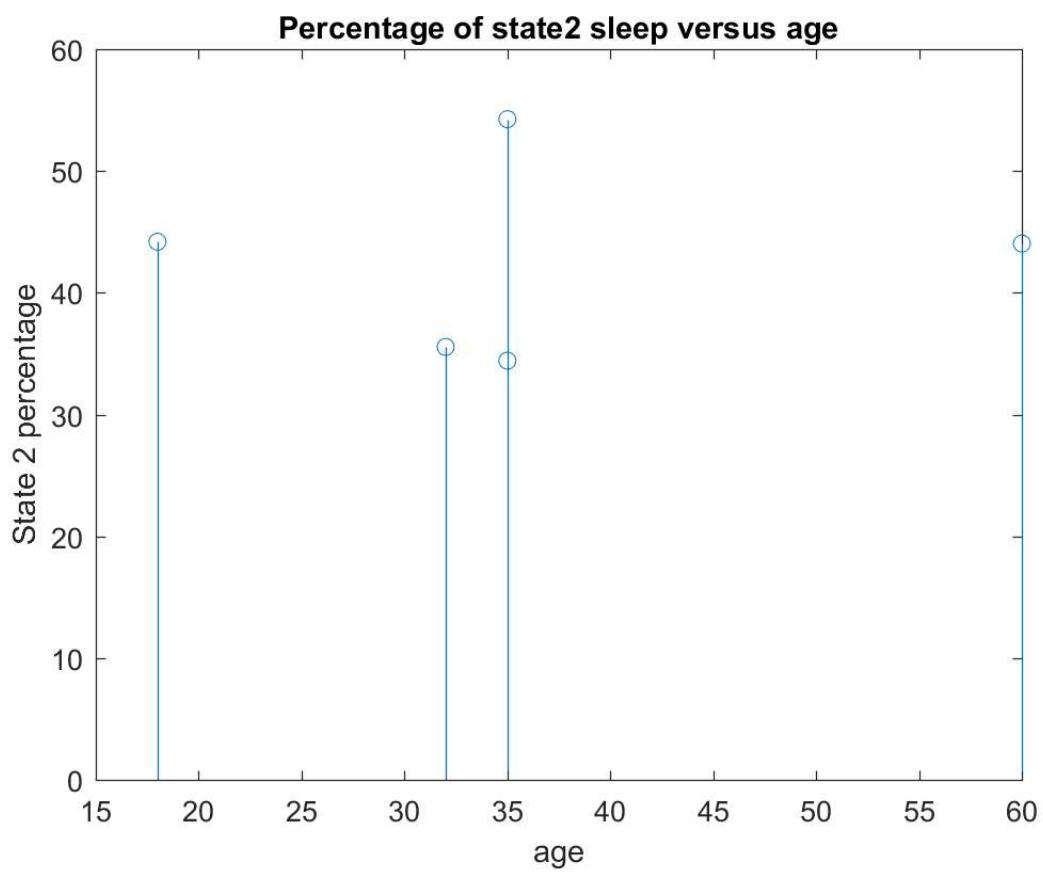
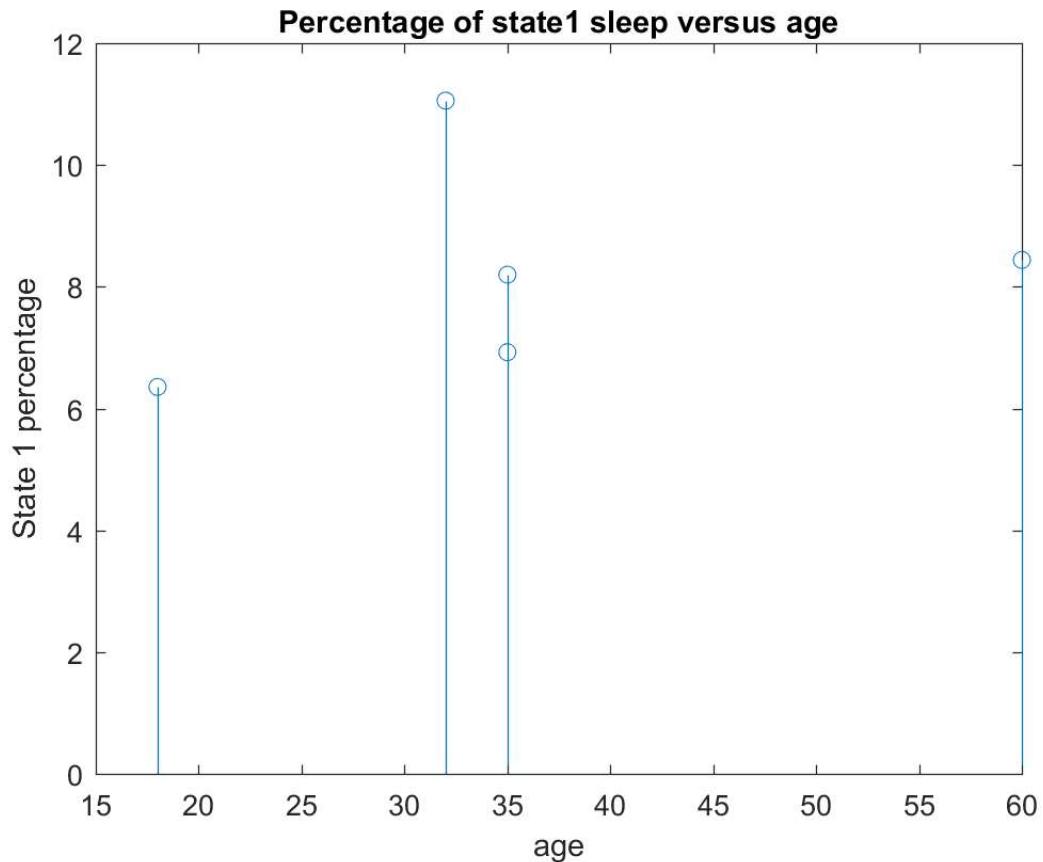
```
Num_state1 = zeros (5,1) ;
Num_state2 = zeros (5,1) ;
Num_state3 = zeros (5,1) ;
Num_state4 = zeros (5,1) ;
Num_stateREM = zeros (5,1) ;
[t state X] = FeatureExtraction ('C:\Users\Alireza\Desktop\Project2\Data\ST7011J0-PSG.edf'
,'C:\Users\Alireza\Desktop\Project2\Data\ST7011JP-Hypnogram_annotations.txt') ;
Num_state1(1) = (length(find(state==1))*100)/length (state) ;
Num_state2(1) = (length(find(state==2))*100)/length (state) ;
Num_state3(1) = (length(find(state==3))*100)/length (state) ;
Num_state4(1) = (length(find(state==4))*100)/length (state) ;
Num_stateREM(1) = (length(find(state==6))*100)/length (state) ;
[t state X] = FeatureExtraction ('C:\Users\Alireza\Desktop\Project2\Data\ST7022J0-PSG.edf'
,'C:\Users\Alireza\Desktop\Project2\Data\ST7022JM-Hypnogram_annotations.txt') ;
Num_state1(2) = (length(find(state==1))*100)/length (state) ;
Num_state2(2) = (length(find(state==2))*100)/length (state) ;
Num_state3(2) = (length(find(state==3))*100)/length (state) ;
Num_state4(2) = (length(find(state==4))*100)/length (state) ;
Num_stateREM(2) = (length(find(state==6))*100)/length (state) ;
[t state X] = FeatureExtraction ('C:\Users\Alireza\Desktop\Project2\Data\ST7041J0-PSG.edf'
,'C:\Users\Alireza\Desktop\Project2\Data\ST7041JO-Hypnogram_annotations.txt') ;
Num_state1(3)= (length(find(state==1))*100)/length (state) ;
Num_state2(3) = (length(find(state==2))*100)/length (state) ;
Num_state3(3) = (length(find(state==3))*100)/length (state) ;
Num_state4(3) = (length(find(state==4))*100)/length (state) ;
Num_stateREM(3) =(length(find(state==6))*100)/length (state) ;
[t state X] = FeatureExtraction ('C:\Users\Alireza\Desktop\Project2\Data\ST7052J0-PSG.edf'
,'C:\Users\Alireza\Desktop\Project2\Data\ST7052JA-Hypnogram_annotations.txt') ;
Num_state1(4) = (length(find(state==1))*100)/length (state) ;
```

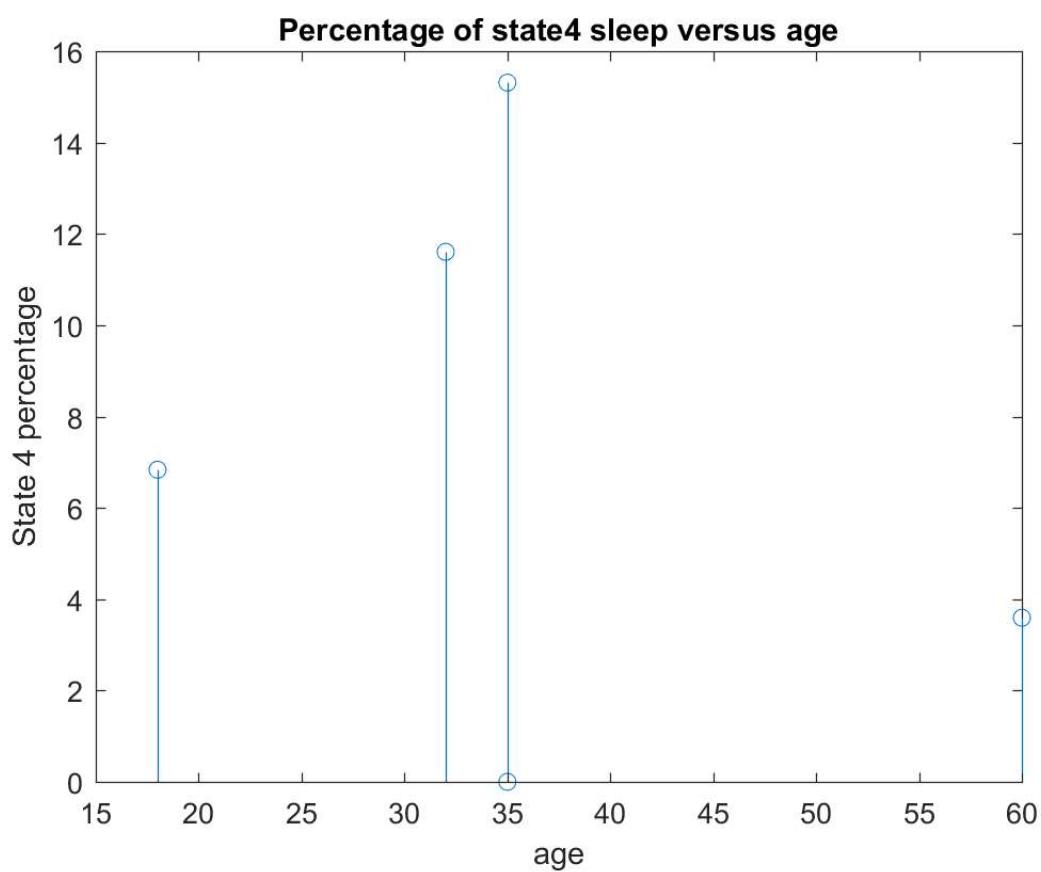
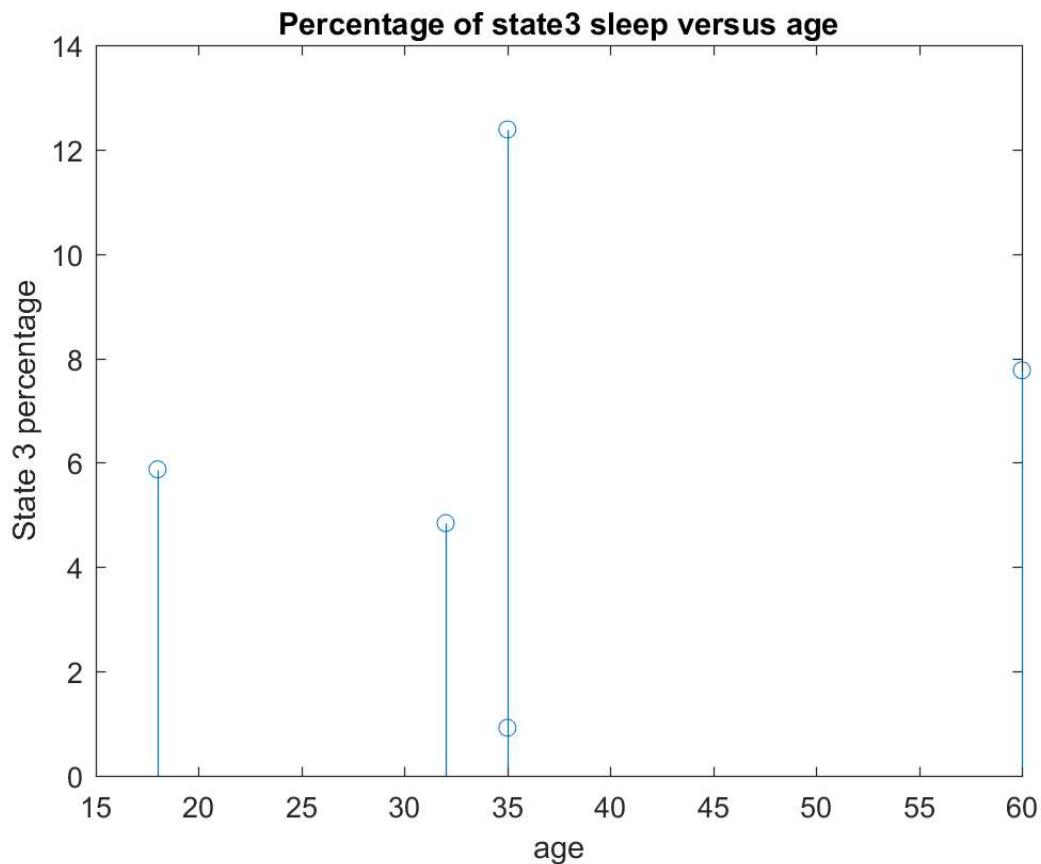
```

Num_state2(4) = (length(find(state==2))*100)/length (state) ;
Num_state3(4) = (length(find(state==3))*100)/length (state) ;
Num_state4(4) = (length(find(state==4))*100)/length (state) ;
Num_stateREM(4) = (length(find(state==6))*100)/length (state) ;
[t state X] = FeatureExtraction ('C:\Users\Alireza\Desktop\Project2\Data\ST7061J0-PSG.edf'
,'C:\Users\Alireza\Desktop\Project2\Data\ST7061JR-Hypnogram_annotations.txt') ;
Num_state1(5) = (length(find(state==1))*100)/length (state) ;
Num_state2(5) = (length(find(state==2))*100)/length (state) ;
Num_state3(5) = (length(find(state==3))*100)/length (state) ;
Num_state4(5) = (length(find(state==4))*100)/length (state) ;
Num_stateREM(5) = (length(find(state==5))*100)/length (state) ;
age = [60 35 18 32 35] ;
figure
stem (age , Num_state1)
xlabel ('age')
ylabel ('State 1 percentage')
title ('Percentage of statel sleep versus age')
figure
stem (age , Num_state2)
xlabel ('age')
ylabel ('State 2 percentage')
title ('Percentage of state2 sleep versus age')
figure
stem (age , Num_state3)
xlabel ('age')
ylabel ('State 3 percentage')
title ('Percentage of state3 sleep versus age')
figure
stem (age , Num_state4)
xlabel ('age')
ylabel ('State 4 percentage')
title ('Percentage of state4 sleep versus age')
figure
stem (age , Num_stateREM)
xlabel ('age')
ylabel ('REM percentage')
title ('Percentage of REM sleep versus age')

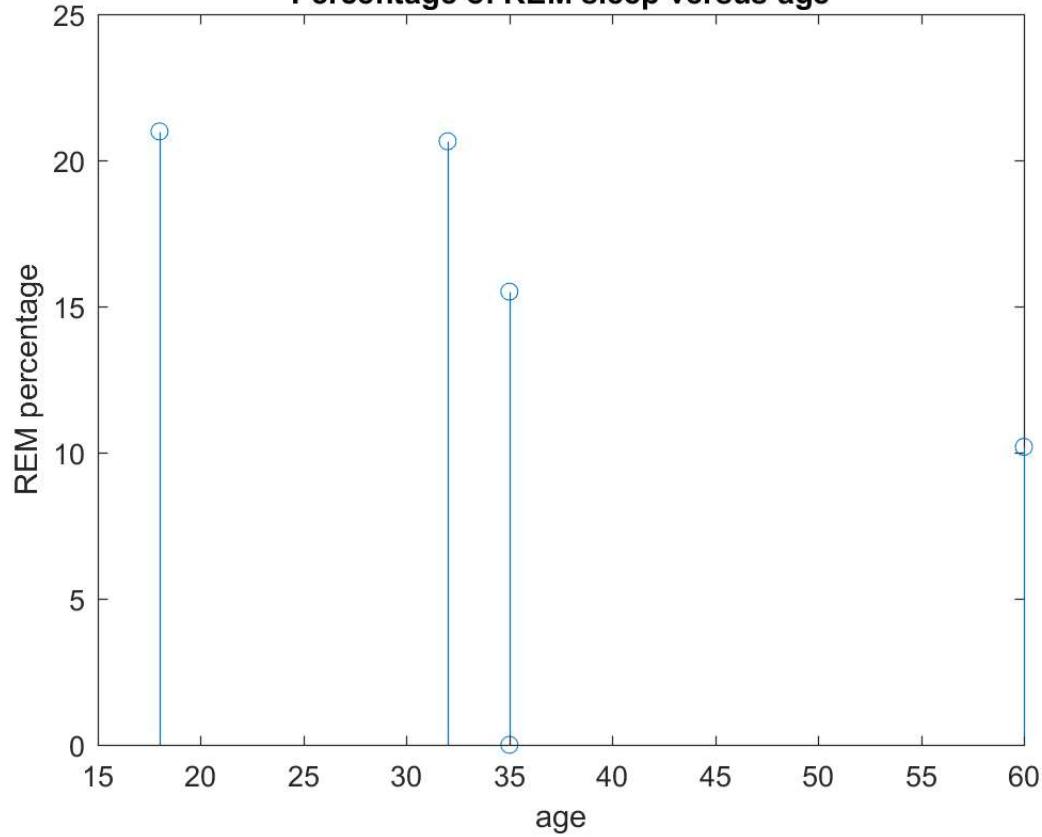
```

Step 1 of 2: Reading requested records. (This may take a few minutes.)...
Step 2 of 2: Parsing data...
Step 1 of 2: Reading requested records. (This may take a few minutes.)...
Step 2 of 2: Parsing data...
Step 1 of 2: Reading requested records. (This may take a few minutes.)...
Step 2 of 2: Parsing data...
Step 1 of 2: Reading requested records. (This may take a few minutes.)...
Step 2 of 2: Parsing data...
Step 1 of 2: Reading requested records. (This may take a few minutes.)...
Step 2 of 2: Parsing data...





Percentage of REM sleep versus age



Published with MATLAB® R2017a